

Национальный исследовательский университет «Высшая школа экономики» · Высшая школа бизнеса


ЛЕКЦИЯ 1

Искусственный интеллект и машинное обучение в финансовой организации

Дисциплина «ИИ и машинное обучение» · магистратура «Бизнес-аналитика и цифровые решения в финансах»

1 курс, модули 1–2, 2026/2027 учебный год

Где мы в курсе



Любое ML-решение проходит один и тот же путь: от бизнес-цели к формулировке ML-задачи, затем к данным, модели, метрикам и внедрению. Курс устроен как последовательное прохождение этой цепочки.

Вывод

Сегодняшняя лекция отвечает на вопрос «какое решение мы принимаем и стоит ли решать эту задачу машинным обучением». Следующая — на вопрос «из каких данных мы это сделаем».

Система оценивания

Элемент контроля	Вес	Когда	Что проверяется
Посещаемость	10 %	Модули 1–2	Лекции и семинары
Аудиторные проверочные	20 %	Темы 3, 5, 7, 9	Четыре работы по 10 минут: логистическая регрессия, бустинг, диагностика/метрики, глубокие сети
Практические задания	25 %	Темы 3, 5, 7, 9	Четыре индивидуальных задания: базовая модель, кейс «кредитный риск и антифрод» и др., нейронные сеть, диагностика/метрики
Итоговый тест	15 %	Тема 12	Все пройденные темы
Итоговый проект	30 %	Конец 2 модуля	Команда 2–3 человека: сквозное ML-решение, презентация до 5 слайдов и защита

Доля посещенных занятий	Вес
<70%	1 %
71-73%	2 %
74-76%	3 %
77-80%	4 %
81-83%	5 %
84-86%	6 %
87-90%	7 %
91-93%	8 %
94-96%	9 %
97-100%	10 %

План лекции


1. Что такое машинное обучение и что современный ИИ
2. Роль ИИ и машинного обучения в финансовой сфере
3. Типовые задачи машинного обучения в финансах: скоринг и кредитный риск, антифрод, отток, спрос, персонализация, анализ текстов
4. От бизнес-задачи к ML-задаче; жизненный цикл ML-решения и основные риски ML

БЛОК 1

Что такое машинное обучение и современный ИИ?

Что такое машинное обучение

Машинное обучение — набор методов, **выявляющих закономерности в данных** и превращающих их в правило, применимое к новым, ранее не виденным объектам.




Машинное обучение – это по сути решение **обратной задачи** выявление закона/правила из данных.

Вывод

Слово «обучение» — метафора. Технически происходит подбор числовых параметров модели так, чтобы её ответы на известных примерах были как можно ближе к правильным — и, что важнее, оставались такими на новых данных.

Что такое современный ИИ

То, что сегодня называют искусственным интеллектом в новостях, — это **генеративные большие языковые модели**. Они не отдельная технология, а третий этап развития одной и той же идеи.



Один принцип на всех этапах: параметры настраиваются по примерам

Этап	Откуда берутся признаки	Что предсказывает модель	Данные
Машинное обучение	Составляет человек (аналитик)	Метку или число	Таблица: строки и столбцы
Глубокое обучение	Строит сама сеть, слой за слоем	Метку, число или вектор	Сырые данные: текст, изображение, звук
Генеративные LLM	Строит сама сеть	Следующий элемент текста	Очень большой корпус текстов

ЗАМЕЧАНИЕ

Способность LLM решать задачи, которым её явно не учили, — побочный эффект масштаба: чтобы хорошо предсказывать продолжение текста, модели приходится усвоить огромный объём закономерностей о мире и языке.

Три способа принять массовое решение

До появления ML банк уже принимал миллионы решений. Машинное обучение конкурирует не с интуицией, а с двумя работающими подходами — и выигрывает не всегда.

Признак сравнения	Экспертное правило	Статистическая модель	Машинное обучение
Источник логики	Знание эксперта	Гипотеза о законе распределения	Закономерность, найденная в данных
Число факторов	Единицы	Десятки	Сотни и тысячи
Главная цель	Управляемость	Объяснение связи	Точность прогноза на новых данных
Проверка качества	Аудит логики	Значимость стат. коэффициентов	Ошибка на отложенной выборке
Слабое место	Не адаптируется решения	Ограниченность предпосылок	Неинтерпретируемость, риск переобучения

Вывод

ML не отменяет два первых подхода: экспертное правило и статистическую модель. В регулируемых процессах итоговое решение обычно гибридное: модель даёт оценку, а экспертные правила определяют её применение.

БЛОК 2

Роль ИИ и машинного обучения в финансовой сфере

Где машинное обучение создаёт стоимость в банке

Экономический эффект возникает не от точности как таковой, а от **массовости решения, умноженной на цену ошибки**. Отсюда четыре критерия отбора задач.

- 1. Массовость** — решение принимается тысячи раз в день, ручная экспертиза недоступна по стоимости;
- 2. Повторяемость** — будущее статистически похоже на прошлое, закономерность устойчива;
- 3. Обратная связь** — исход решения наблюдаем и возвращается в данные (дефолт, отток);
- 4. Измеримая цена ошибки** — известна стоимость ложного срабатывания и пропуска.


ОЦЕНКА ЭФФЕКТА ДО НАЧАЛА ПРОЕКТА

Поток 40 тыс. заявок в месяц, средний лимит 180 тыс. ₽, доля дефолтов 6 %. Снижение доли дефолтов на 0,5 % при неизменном уровне одобрения даёт $0,005 \times 40\,000 \times 180\,000 \times 0,45 \approx 16$ млн ₽ в месяц **снижения** ожидаемых **потерь**. Эта оценка делается **до** обучения модели и определяет допустимый бюджет проекта.

РИСКОВАННАЯ ЗАДАЧА ДЛЯ ML

Стратегические разовые решения (сделка M&A, выбор стратегии) не удовлетворяют критериям 1 и 3: примеров мало, обратная связь приходит через годы. Это не задача ML.

От прогноза к решению: модель не решает, решает правило



Контур принятия решения: модель занимает только один из семи блоков

Модель выдаёт **число** — вероятность, ранг или прогноз величины. Решение появляется только после наложения порога, бизнес-ограничений и стоимости ошибок.

ОДИН ПРОГНОЗ — ТРИ РАЗНЫХ РЕШЕНИЯ

- $p = 0,08$ и лимит 50 тыс. ₽ — одобрить автоматически;
- $p = 0,08$ и лимит 3 млн ₽ — отправить на ручную андеррайтинг-экспертизу;
- $p = 0,08$ в антифроде — заблокировать операцию до подтверждения клиентом.

ВЫВОД

Одна и та же вероятность приводит к разным действиям, потому что различаются цена ошибки и регуляторные требования. Порог — это бизнес-решение, а не свойство модели.

БЛОК 3

Типовые задачи машинного обучения в финансах

Скоринг и кредитный риск, антифрод, отток, спрос, персонализация и анализ текстов

Кредитный скоринг и вероятность дефолта

Кредитный скоринг — оценка вероятности того, что заёмщик не исполнит обязательства в заданном горизонте, по данным, доступным **на момент принятия решения** о выдаче.

Целевая переменная строится по регуляторному определению дефолта: просрочка 90+ дней в течение 12 месяцев после выдачи.

$$y_i = 1, \text{ если наступил дефолт в окне } [t_0, t_0 + 12 \text{ мес}]; \text{ иначе } y_i = 0$$

Модель оценивает $PD_i = p(y_i = 1 \mid x_i)$ — Probability of Default для клиента i .

ЗАМЕЧАНИЕ

Тип задачи — бинарная классификация с калиброванной вероятностью: важна не только упорядоченность заёмщиков, но и абсолютное значение PD, поскольку оно входит в расчёт резервов.

Кредитный риск: от вероятности к ожидаемым потерям

Скоринговая модель — лишь одна из трёх компонент оценки кредитного риска.

$$EL = PD \times LGD \times EAD$$

ожидаемые потери по одному кредитному требованию

PD — вероятность дефолта в горизонте 12 месяцев (0–1) — предмет **ML-модели**, Probability of Default

LGD — часть средств, которую банк не сможет вернуть, даже реализовав залог (продав заложенное имущество при дефолте), Loss Given Default (0–1)

EAD — какая сумма окажется под угрозой, если заёмщик перестанет выполнять свои обязательства, Exposure at Default

ПРОБЛЕМА · ОЖИДАЕМЫЕ ПОТЕРИ ПОРТФЕЛЯ

$$EL_i = PD_i \cdot LGD_i \cdot EAD_i \quad \text{потери по одному требованию как математическое ожидание}$$

$$EL = \sum_i EL_i \quad \text{аддитивность математического ожидания: корреляции не нужны}$$

$$\Delta EL = EAD \cdot LGD \cdot \Delta PD \quad \text{эффект уточнения модели при фиксированных LGD и EAD}$$

Портфель 100 млрд ₽, LGD = 0,45: снижение среднего PD на 0,2 п. п. даёт 90 млн ₽ в год.

ВЫВОД

Ценность точности модели измеряется в рублях через эту цепочку, а не в единицах метрики классификации.

Антифрод: выявление редких событий

Доля мошеннических операций в эквайринговом потоке — сотые доли процента. Это меняет интерпретацию даже очень хорошей модели.

ПРОБЛЕМА · ДОЛИ ВЕРНЫХ СРАБАТЫВАНИЙ ПО ФОРМУЛЕ БАЙЕСА

$p(F) = 0,001$ базовая частота фрода: 1 операция из 1000

$p(A|F) = 0,80$ модель ловит 80 % мошеннических операций

$p(A|\neg F) = 0,01$ и ошибочно тревожит на 1 % честных операций

$p(F|A) = p(A|F)p(F) / [p(A|F)p(F) + p(A|\neg F)p(\neg F)]$ формула Байеса

$p(F|A) = 0,0008 / (0,0008 + 0,00999) \approx 0,074$ верен лишь каждый 13-й алерт

При 1 млн операций в день это $800 + 9990 = 10\,790$ алертов, из которых 9 990 — ложные.

ВЫВОД

Редкость события, а не слабость модели, делает точность низкой. Именно поэтому в антифроде управляют порогом и стоимостью разбора алерта, а ассурасу как метрика бесполезна.

Отток клиентов, спрос и денежные потоки

ОТТОК (CHURN) — БИНАРНАЯ КЛАССИФИКАЦИЯ

Ключевая трудность — определение таргета: явного «расторжения» в рознице часто нет. Оттоком считают падение активности ниже порога в течение временного окна: например, ноль транзакций по карте за 90 дней при наличии активности в предыдущие 90 дней.

СПРОС, ОСТАТКИ, ДЕНЕЖНЫЕ ПОТОКИ — РЕГРЕССИЯ И ПРОГНОЗ РЯДОВ

Предсказывается непрерывная величина: спрос на наличные в банкомате, объём выдач, остатки на счетах. Наблюдения упорядочены во времени, поэтому случайное перемешивание выборки недопустимо.

Задача	Тип	Единица наблюдения	Горизонт
Отток розничного клиента	Классификация	Клиент — месяц	90 дней
Спрос на наличные в банкомате	Регрессия	Банкомат — день	1–14 дней
Остатки на счетах для казначейства	Регрессия	Портфель — день	1–3 месяца

Персонализация и анализ текстов

ПЕРСОНАЛИЗАЦИЯ И РЕКОМЕНДАЦИИ

Задача ранжирования: упорядочить продукты, предложения и подписки по вероятности отклика конкретного клиента. Качество измеряется метриками заточенными на порядок выдачи позиций в списке, а не точностью по всем парам «клиент — продукт».

АНАЛИЗ ТЕКСТОВ

- классификация обращений в поддержку по темам и маршрутизация;
- извлечение сущностей из договоров и платёжных поручений;
- оценка тональности отзывов и новостного фона по контрагенту;
- проверка полноты комплекта документов.

ЗАМЕЧАНИЕ

Текст и изображения — неструктурированные данные: перед моделью их необходимо перевести в числовые векторы. Этим занимаются глубокие сети (темы 10 и 11).

БЛОК 4

От бизнес-задачи к ML-задаче

Жизненный цикл ML-решения и основные риски ML

Четыре вопроса, на которые надо ответить, чтобы трансформировать бизнес-задачу в ML-задачу

- 1. Объект анализа.** Что является *объектом* обучающей выборки: клиент, заявка, операция или пара «клиент — месяц»?
- 2. Целевая переменная.** Какая характеристика *объекта* предсказывается, как она формально определена?
- 3. Момент прогноза.** На какую дату фиксируется набор признаков *объекта*? Всё, что появилось позже, использовать нельзя.
- 4. Действие.** Какое решение изменится от прогноза целевой переменной *объекта* и какова цена ошибки?


ВАЖНО ОПРЕДЕЛИТЬ ОБЪЕКТ!

«Снизить потери от фрода» можно поставить как задачу об **операции** (блокировать конкретный платёж, миллионы *объектов* в сутки, решение за 50 мс) или как задачу о **клиенте** (пометить счёт как скомпрометированный, сотни тысяч *объектов*, решение за сутки). Это две разные модели, разные данные и разные метрики.

ВЫВОД

Ответы на эти четыре вопроса — самое главное перед решением бизнес-задачи с помощью ML.

Жизненный цикл ML-решения



Цикл замкнут: данные мониторинга возвращаются в постановку задачи, а деградация качества запускает переобучение модели на свежих данных.

Этап	Доля трудозатрат	Главный вопрос этапа
Постановка задачи	≈ 10 %	Какое решение изменится и какова цена ошибки
Данные и признаки	≈ 60 %	Что было известно на момент прогноза
Обучение и оценка	≈ 15 %	Устойчиво ли качество на новых данных
Внедрение и мониторинг	≈ 15 %	Воспроизводится ли качество в эксплуатации

Вывод

Подбор алгоритма — самый короткий этап. Качество решения определяется постановкой задачи и корректностью данных.

Четыре группы рисков ML-решения

Риск	Как проявляется	Как контролируется
Переобучение	Высокое качество на обучении, низкое на новых данных	Отложенная и out-of-time валидация, регуляризация, контроль сложности
Смещение (bias)	Систематическая ошибка на отдельных группах клиентов или периодах	Анализ качества в разрезах, проверка репрезентативности выборки
Неинтерпретируемость	Решение нельзя объяснить клиенту, аудитору и регулятору	Интерпретируемые модели, SHAP/LIME, документирование логики
Этика и регуляторика	Использование недопустимых признаков, нарушение прав субъекта данных	Правовая экспертиза перечня признаков, защита персональных данных, аудит

ВНИМАНИЕ!

Три из четырёх рисков не обнаруживаются метриками качества. Какие именно?😊

Когда машинное обучение НЕ нужно?

Когда машинное обучение НЕ нужно?

- **Решение принимается редко** и требует объяснимой стратегии, а не прогноза.
- **Есть точное правило.** Если закон или договор однозначно определяют исход, модель лишь добавит ошибку.
- **Нет обратной связи.** Исход решения не наблюдается, обучающую выборку собрать нельзя.
- **Данные не отражают будущее.** Процесс изменился настолько, что история перестала быть информативной.
- **Стоимость владения выше эффекта.** Поддержка, мониторинг и валидация модели стоят дороже выигрыша от её точности.

ПРОВЕРКА НА АЛЬТЕРНАТИВУ ПЕРЕД СТАРТОМ ПРОЕКТА

Прежде чем обучать модель, строят **базовое решение**: текущее экспертное правило, константный прогноз или простую логистическую регрессию на пяти признаках. Если сложная модель не превосходит базовое решение с запасом, покрывающим стоимость её сопровождения, проект закрывается на этом шаге.

ЗАМЕЧАНИЕ

Честный вывод «ML здесь не нужен» — такой же профессиональный результат аналитика, как обученная модель.

Итоги лекции

1. Машинное обучение — извлечение закономерности из данных: человек задаёт примеры правильных ответов, правило программа находит сама.
2. Современный ИИ — генеративные модели: ML → глубокое обучение → LLM; в банке актуальны табличные модели, не только ИИ.
3. Ценность модели измеряется в прибыли через цепочку «прогноз → порог → действие → эффект», а не в единицах метрики качества ML-модели.
4. Постановка ML-задачи — требует четыре сущности: объект, целевая переменная объекта, момент прогноза, действие.
5. Риски внедрения — переобучение, смещение, непрозрачность, этика и регуляторика — контролируются процессом, а не метрикой.

Вывод

На следующей лекции обсудим самый важный вопрос: подготовка данных для обучения ML-модели