

Национальный исследовательский университет «Высшая школа экономики» · Высшая школа бизнеса

ЛЕКЦИЯ 2

Постановка задачи и подготовка данных для машинного обучения

Дисциплина «ИИ и машинное обучение» · магистратура «Бизнес-аналитика и цифровые решения в финансах»

1 курс, модули 1–2, 2026/2027 учебный год

План лекции

1. Формальная постановка и типы задач
2. Объект анализа, целевая переменная, признаки
3. Разбиение выборки: train, validation, test
4. Подготовка числовых и категориальных признаков
5. Дисбаланс, смещение, утечка и воспроизводимость

Продолжаем: от карточки задачи к обучающей выборке

Вопрос из лекции 1	Ответ	Что из этого следует сегодня
Объект анализа	Пара «клиент — месяц»	Надо разбивать выборку по клиенту, а не времени
Целевая переменная	Нет транзакций 90 дней	Последние три месяца истории использовать нельзя
Момент прогноза	Последний день месяца	Признаки будущего не должны попасть в обучающую выборку
Действие	Топ-5 % на удержание	Важно не «уйдет/не уйдет», а ранжирование по потенциальной потере прибыли
Цена ошибки	800 Р против 14 000 Р	Из-за дисбаланса порог задаётся, исходя из потенциальной потери прибыли

Вывод

Правая колонка — это и есть план лекции. Каждая строка таблицы – «инструкция» по собору данных для решения задачи.

БЛОК 1

Формальная постановка и типы задач

Что именно оптимизируется при обучении и чем различаются классификация, регрессия и ранжирование.

Формальная постановка обучения с учителем

$$D = \{(x_i, y_i)\}_{i=1}^n, x_i \in \mathbb{R}^d, y_i \in Y$$

$$f: \mathcal{X} \rightarrow \mathcal{Y}, f \in \mathcal{F}, L: \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}_+$$

выборка, класс моделей и функция потерь

x_i — вектор признаков объекта, известный к моменту прогноза

y_i — наблюдаемый исход; для скоринга — $\{0, 1\}$, для спроса — вещественное число

$\mathcal{F}$ — класс моделей: линейные функции, деревья, нейронные сети

$L(y, \hat{y})$ — цена одной ошибки предсказания

ЗАМЕЧАНИЕ

Предполагается, что пары (x_i, y_i) независимо получены из неизвестного распределения $P(x, y)$, одного и того же в обучении и в эксплуатации. В реальности это предположение нарушается регулярно — отсюда валидация во времени и мониторинг.

Минимизация эмпирического риска

ВЫВОД · ПОСТАНОВКИ ЗАДАЧИ ОБУЧЕНИЯ

$$R(f) = \mathbb{E}_{(x,y) \sim P}[L(y, f(x))]$$

истинный риск: то, что мы хотим минимизировать

$R(f)$ недоступен

распределение P неизвестно, доступна только выборка

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i))$$

эмпирический риск — среднее по обучающей выборке

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \hat{R}(f)$$

принцип минимизации эмпирического риска

$$R(\hat{f}) - R(f^*) = [R(\hat{f}) - \hat{R}(\hat{f})] + [\hat{R}(\hat{f}) - \hat{R}(f^*)] + [\hat{R}(f^*) - R(f^*)]$$

переобучение + погрешность оптимизации + случайность выборки

ВЫВОД

Первое слагаемое растёт с богатством класса F — это и есть переобучение. Вся практика ML состоит в удержании **баланса** между гибкостью модели и объёмом данных.

Типы задач обучения с учителем

Во всех задачах есть выборка пар «объект — известный исход». Различаются они только множеством Y и, как следствие, функцией потерь и метрикой.

Тип задачи	Множество Y	Что выдаёт модель	Базовая функция потерь
Бинарная классификация	$\{0, 1\}$	Вероятность класса	Логистические потери
Многоклассовая классификация	$\{1, ..., K\}$	Вектор вероятностей	Перекрёстная энтропия
Регрессия	вещественная прямая	Число	Квадратичные или абсолютные потери
Ранжирование и рекомендации	порядок	Оценка релевантности пары	Попарные и списочные потери (классификация/регрессия)

$$L_{\log} = -[y \log(\hat{p}) + (1 - y)\log(1 - \hat{p})]$$
$$L_2 = (y - \hat{y})^2$$
$$L_1 = |y - \hat{y}|$$

потери для классификации и для регрессии

Вывод

Выбор типа задачи — не техническая деталь: он задаёт метрику, по которой будет приниматься решение о внедрении, и схему валидации.

БЛОК 2

Объект анализа, целевая переменная, признаки

Как сконструировать признаки объекта обучающей выборки, зафиксировать момент прогноза и оценить, достаточно ли данных.

Объект анализа

Из одних и тех же данных можно построить разные выборки. Выбор объекта анализа меняет размер выборки, схему валидации и сам смысл прогноза.

ОДНА БОЛЬНИЦА, ТРИ РАЗНЫЕ ЗАДАЧИ

Объект анализа	Что предсказываем	Размер выборки
Пациент	Будет ли осложнение в течение года	#пациентов
Госпитализация	Повторная госпитализация в 30 дней после выписки	#пациентов X #дней
Пациент — день	Ухудшение состояния завтра	#пациентов X #дней X #госпитализаций

Задача	Объект анализа	Необходимая инфа об объекте в Train и Test
Скоринг заявки	Заявка на кредит	Заявка
Отток подписчика	Пара «подписчик — месяц»	Подписчик
Антифрод	Платёжная операция	Клиент или карта (операции одного клиента похожи друг на друга)

РИСК

Если одному человеку соответствует несколько строк, они **зависимы**. Случайное разбиение разнесёт их по обучению и тесту, и модель запомнит человека, а не закономерность.

Целевая переменная: что именно вы предсказываете?

Целевая переменная — характеристика объекта, которая предсказывается на основе признаков этого объекта. Три обязательных элемента для верного определения целевой переменной: **событие**, **окно** и **исключения**.

ОТТОК ПОДПИСЧИКА: СОБЫТИЯ «РАСТОРЖЕНИЕ» НЕ СУЩЕСТВУЕТ

- «отменил автопродление» — явное действие, но так поступают единицы: большинство просто перестаёт пользоваться;
- «ноль сессий за 30 дней» — слишком рано: часть подписчиков возвращается;
- **«ноль сессий за 90 дней при активности в предыдущие 90» — рабочее определение;**
- исключения: подарочные подписки и технические аккаунты.


ГОСПИТАЛИЗАЦИЯ: СОБЫТИЕ ЕСТЬ, НО ТРЕБУЕТ ОГОВОРК

«Повторная госпитализация в течение 30 дней после выписки» — стандартное определение. Плановые повторные госпитализации, например курс химиотерапии, исходом *не считаются*: иначе модель будет предсказывать расписание лечения, а не риск.

ВЫВОД

Чем длиннее временное окно, тем больше целевая переменная подвержена к риску стать неактуальной для прогноза и тем меньше свежих данных доступно для обучения. Этот компромисс фиксируется до сбора выборки.

Момент прогноза



Госпитализация: признаки — строго до выписки, исход — строго после

Момент прогноза t_0 — момент, когда в реальном процессе принимается решение. Правило: **каждый признак должен иметь дату появления значения, строго меньшую t_0** .

РИСК

Классический пример утечки в медицине: признак «назначен препарат для контроля состояния». Назначение сделано на повторном приёме, то есть уже после выписки. Модель получает ROC-AUC 0,95 на истории и бесполезна в момент выписки, когда назначения ещё нет.

Что может быть признаком

Признак — измеримая характеристика объекта, значение которой достоверно известно на момент прогноза t_0 и будет доступно в эксплуатации в тот же момент.

Группа признаков	Пример: подписка	Пример: госпитализация
Профиль объекта	Тариф, срок подписки, устройство	Возраст, пол, хронические диагнозы
Поведенческие агрегаты	Часы просмотра за 1, 3, 12 недель	Число госпитализаций за 12 месяцев
Динамика	Отношение последней недели к среднему за квартал	Изменение показателей анализов за время лечения
Контекст	Выход премьер, акции, сезон	Загрузка отделения, сезон

РИСК
Две группы признаков всегда требуют проверки: любые «максимумы за всё время» и любые поля, обновляемые задним числом в учётной системе. И то и другое почти наверняка содержит информацию из будущего.

Конструирование признаков

Признаки почти никогда не лежат в данных готовыми. Их конструируют из событийных логов — и это самая трудозатратная часть проекта.

Способ конструирования	Как считается	Что улавливает
Сбор по временным окнам	Сумма, количество, среднее за 1, 3, 12 периодов	Уровень активности
Отношения окон	Последний период к среднему за год	Изменение поведения, а не его уровень
Время с события	Количество дней с последней операции, визита, обращения	Затухание активности — часто сильнейший признак оттока
Счётчики и частоты	Число уникальных категорий, доля крупнейшей	Разнообразие и концентрацию поведения
Лаги и тренды	Значение месяц назад, наклон по трём точкам	Направление динамики
Признаки-флаги	Был ли контакт с поддержкой, был ли отказ платежа	Редкие, но информативные события

Вывод

Правило: сначала десятков осмысленных признаков по этим шаблонам, потом сложная модель. Обратный порядок почти всегда даёт **худший результат**.

Сколько данных нужно

Вопрос почти всегда ставят **неправильно**: считают строки в таблице данных. Считать нужно **события** — объекты редкого класса, потому что именно они несут информацию о том, что мы предсказываем.

$$\# \text{событий} / \# \text{признаки} \geq 10$$

эмпирическое правило: меньше 10 событий на признак — модель неустойчива

ОДНА ВЫБОРКА, ТРИ РАЗНЫХ ОТВЕТА

Ситуация	Строк в базе данных	События	Признаков	На признак	Вывод
Отток подписчиков	600 000	18 000	120	150	Данных достаточно
Скоринг нового продукта	8 000	320	80	4	Сократить до 20–30 признаков
Редкое осложнение (медицина)	40 000	90	60	1,5	ML преждевременно

ВЫВОД

Если событий на признак мало, работают три выхода: сократить число признаков, расширить окно наблюдения или сменить таргет на более частый — например, просрочку 30+ вместо дефолта.

БЛОК 3

Разбиение выборки: **train, validation, test**

Зачем нужны три части, чем кросс-валидация лучше однократного отложения и почему разбиение по времени и по группам обязательно.

Три части выборки и три разные роли

Часть	Доля	Роль	Сколько раз используется
Train — обучающая	60–70 %	Настройка параметров модели	Множественно
Validation — валидационная	15–20 %	Выбор гиперпараметров, порога, модели	Множественно
Test — тестовая	15–20 %	Однократная честная оценка качества	Один раз

Разделение validation и test — следствие статистики: выбирая лучшую из k моделей по валидации, мы максимизируем **случайную удачу** и смещаем оценку вверх. **Ложно смещаем! Поэтому нужен Test!**

$$\mathbb{E}[\max_{j=1..k} \hat{R}_j] > \max_{j=1..k} \mathbb{E}[\hat{R}_j]$$

чем больше вариантов перебрано, тем оптимистичнее оценка на той же выборке

РИСК

Множественное обращение к тестовой выборке превращает её в валидационную. После этого честной оценки качества в проекте не остаётся.

Кросс-валидация

При ограниченной выборке однократное отложение даёт неустойчивую оценку: результат зависит от того, какие объекты попали в отложенную часть.

ВЫВОД · ОЦЕНКИ КАЧЕСТВА ПО K БЛОКАМ

$D = D_1 \cup D_2 \cup \dots \cup D_K$ выборка делится на K непересекающихся блоков

f_k обучается на $D \setminus D_k$ каждый блок по очереди становится проверочным

$\hat{R}_k = \frac{1}{|D_k|} \sum_{i \in D_k} L(y_i, f_k(x_i))$ оценка качества на своём блоке

$\hat{R}_{CV} = \frac{1}{K} \sum_{k=1}^K \hat{R}_k$ итоговая оценка — среднее по блокам


$s^2 = \frac{1}{K-1} \sum_{k=1}^K (\hat{R}_k - \hat{R}_{CV})^2$ разброс показывает устойчивость модели

Обычно $K = 5$. Каждый объект ровно один раз побывал в проверочной части.

ВЫВОД

Сообщать нужно пару «среднее $\pm$ разброс». Разница средних значений ROC-AUC в 0,003 при разбросе 0,010 статистически неразличима.

Валидация во времени



время → *Out-of-time валидация: проверочный период строго позже обучающего*

- **Подписочный сервис:** сезонность и выход крупных премьер меняют поведение — модель, обученная на декабре, не описывает июль;
- **Банк:** меняются макроусловия, продуктовые правила и состав потока заявок;
- **Больница:** меняются протоколы лечения и состав пациентов.

ЗАМЕЧАНИЕ

Если на объектах одного периода модель даёт 0,78, а на следующем квартале 0,74, то мы знаем скорость устаревания и можем назначить регламент переобучения. Если разрыв близок к нулю, модель стабильна и переобучать её можно реже

Схема	Что проверяет	Вопрос, на который отвечает
Out-of-sample (OOS)	Другие объекты того же периода	Переносится ли модель на новых клиентов
Out-of-time (OOT)	Более поздний период	Будет ли модель работать завтра

ВЫВОД

Разрыв качества между OOS и OOT — прямая оценка скорости устаревания модели и основание для регламента переобучения.

БЛОК 4

Подготовка числовых и категориальных признаков

Масштабирование, пропуски и кодирование категорий — и почему все преобразования настраиваются только на обучающей части.

Числовые признаки: масштаб и выбросы

$$z = \frac{x - \mu}{\sigma} - \text{стандартизация}$$

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} - \text{minmax нормализация}$$

$$x' = \log(1 + x) - \log \text{ нормализация}$$

μ, σ, минимум и максимум вычисляются ТОЛЬКО на обучающей части

Модель	Нужно ли масштабирование	Причина
Линейная и логистическая регрессия	Да	Регуляризация штрафует веса — масштабы должны быть сопоставимы
Метод ближайших соседей, SVM	Да	Расстояние определяется масштабом признаков
Деревья, случайный лес, бустинг	Нет	Разбиения инвариантны к монотонным преобразованиям и поиску порога
Нейронные сети	Да	Иначе градиентный спуск сходится крайне медленно

ЗАМЕЧАНИЕ

Величины вроде доходов, оборотов, длительности просмотра и времени лечения сильно скошены вправо. Логарифмирование и нормировка по 1-му и 99-му перцентилям обычно полезнее удаления строк-выбросов.

Пропуски: механизм важнее метода заполнения

Прежде чем заполнять пропуск, нужно понять **почему значения нет** — от этого зависит и метод, и сама допустимость признака.

Механизм	Пример	Корректная обработка
Случайный	Сбой при выгрузке поля	Медиана по обучающей части + флаг пропуска
Связанный с другими признаками	Нет данных о доходе у самозанятого	Заполнение по группе + флаг пропуска
Информативный	Анализ не назначен, потому что врач счёл случай лёгким	Отдельная категория «нет данных»: сам факт пропуска несёт сигнал

Вывод

Медицинский пример показывает суть: отсутствие анализа — это не отсутствие информации, а закодированное решение врача. Заполнение такого пропуска средним **портит** самый сильный признак в выборке.

Замечание

Флаг пропуска почти всегда стоит добавлять отдельным столбцом: для деревьев и бустинга он часто оказывается информативнее заполненного значения.

Вопрос

Когда еще отсутствие признака это **фича**, а не баг?

Категориальные признаки: способы кодирования

Способ	Как устроен	Когда применять
One-hot	Один бинарный столбец на категорию	Мало категорий (< 15), линейные модели и сети
Порядковый	Категория → номер по осмысленному порядку	Есть естественный порядок: стадия заболевания, уровень тарифа
Частотный	Категория → её доля в выборке	Много категорий, деревья и бустинг
Целевой (target / mean)	Категория → среднее значение таргета в ней	Много категорий, но требует защиты от утечки
WOE	Логарифм отношения долей классов	Скоринговые карты, требование интерпретируемости

$$WOE_g = \log \frac{Good_g / Good_{Total}}{Bad_g / Bad_{Total}}$$

доля «хороших» в группе g к доле «плохих» — стандарт скоринговых карт

WOE (Weight of Evidence) — это логарифм отношения того, насколько часто данная группа встречается среди хороших клиентов по сравнению с плохими.

Целевое кодирование и утечка внутри обучения

Целевое кодирование заменяет категорию средним значением таргета. Если считать это среднее по всей обучающей выборке, значение объекта участвует в кодировании самого себя — признак «подглядывает» в собственный ответ.

ВЫВОД · СГЛАЖЕННОГО ЦЕЛЕВОГО КОДИРОВАНИЯ

$$c_g = \frac{1}{n_g} \sum_{i \in g} y_i$$
 наивное среднее — переобучается на редких категориях

$$c_g = \frac{\sum_{i \in g} y_i + \alpha \bar{y}}{n_g + \alpha}$$
 сглаживание к общему среднему с весом α

$$n_g \rightarrow 0 \Rightarrow c_g \rightarrow \bar{y}$$
 редкая категория получает общее среднее

$$n_g \rightarrow \infty \Rightarrow c_g \rightarrow \frac{1}{n_g} \sum_{i \in g} y_i$$
 частая категория получает собственную оценку


Дополнительно кодирование считают по блокам кросс-валидации: для объекта из блока k используются только объекты остальных блоков.

РИСК

Целевое кодирование без сглаживания и без разбиения — самая частая причина разрыва между отличным качеством на обучении и провалом в эксплуатации.

Единый конвейер преобразований

Все преобразования — заполнение пропусков, масштабирование, кодирование — имеют **обучаемые параметры**. Их вычисляют на обучающей части и применяют без пересчёта к валидации, тесту и потоку в эксплуатации.



Единый объект: обучается целиком на train, применяется целиком в эксплуатации

- **Неверно:** масштабировать всю выборку, затем разбить на обучение и тест — статистики теста попали в обучение;
- **Верно:** разбить, вычислить параметры на обучающей части, применить к остальным.

Вывод

Организационное следствие: обучение и продакшен используют один и тот же конвейер, сохранённый как единый артефакт. Расхождение обучающего и продакшен препроцессинга — источник ошибок, не видимых ни в одной метрике.

БЛОК 5

Дисбаланс, смещение, утечка и воспроизводимость

Четыре свойства данных, которые определяют, будет ли модель работать за пределами обучающей выборки.

Дисбаланс классов

Дисбаланс — не ошибка данных, а свойство задачи: дефолты, мошенничество, отток и осложнения редки по природе.

Задача	Доля положительного класса	Следствие
Мошеннические операции	0,05–0,2 %	Accuracy бесполезна; нужны PR-AUC и порог
Дефолт по кредиту	3–8 %	Пороги много ниже 0,5; калибровка обязательна
Отток подписчика за месяц	3–5 %	Ранжирование важнее метки
Госпитализация в 30 дней	12–20 %	Умеренный дисбаланс, обычных приёмов достаточно

Приём	Суть	Замечание
Веса классов	Редкий класс получает больший вес в функции потерь	Предпочтительный вариант: данные не искажаются
Настройка порога	Порог выбирается по стоимости ошибок	Обязательный шаг в любом случае
Undersampling / oversampling	Часть большинства выбрасывается либо редкий класс дублируется	Только на обучающей части; требует перекалибровки

РИСК

Любая балансировка применяется **только к обучающей части**. Валидация и тест сохраняют реальную долю классов, иначе выбранный порог не перенесётся в эксплуатацию.

Смещение выборки

Смещение выборки (selection bias) — обучающая выборка формируется не из тех объектов, к которым модель будет применяться.

ОДИН МЕХАНИЗМ В ДВУХ ОТРАСЛЯХ

- **Скоринг:** модель обучается на выданных кредитах, поскольку исход известен только по ним, но применяется ко *всем* заявкам, включая отказанные прошлой системой;
 - **Медицина:** модель риска обучается на госпитализированных пациентах, но решение о госпитализации принимал врач — лёгкие случаи в выборку не попали.
-
- **Смещение выживших** — в данных остались только «дожившие» объекты;
 - **Смещение обратной связи** — рекомендации обучаются на откликах, полученных по прошлым же рекомендациям.

ВЫВОД

Проверка: сравнить распределения признаков в обучающей выборке и в реальном потоке. Существенное расхождение — сигнал смещения ещё до обучения модели.

Утечка данных: четыре типа

Тип утечки	Как выглядит	Как обнаружить
Из будущего	Признак содержит данные, появившиеся после момента прогноза	Проверить дату появления значения каждого признака
Через таргет	Признак — функция от целевой переменной: «дата выписки из повторной госпитализации», «сумма списания»	Аномально высокая важность одного признака
Через препроцессинг	Статистики и кодирование считались до разбиения	Пересмотреть порядок операций в конвейере
Через дубликаты	Одни и те же объекты в обучении и тесте	Проверка пересечений

Вывод

Практический индикатор: качество заметно выше отраслевого ориентира. Для розничного скоринга ROC-AUC 0,70–0,80 — норма, для прогноза госпитализации — 0,65–0,75. Значение 0,95 почти наверняка означает утечку, а не превосходную модель.

Воспроизводимость

Результат считается полученным, только если его можно воспроизвести. Для этого фиксируются пять вещей.

1. **Данные** — срез витрины на дату, а не «текущее состояние» таблицы;
2. **Код** — версия в репозитории с конкретным коммитом;
3. **Окружение** — версии библиотек: различия в версиях меняют результат;
4. **Случайность** — фиксированное зерно генератора для разбиения и обучения;
5. **Параметры и метрики** — сохранённый журнал эксперимента.

ЗАМЕЧАНИЕ

Требование воспроизводимости — не просто формальность. Модель кредитного риска подлежит валидации и аудиту, а невозпроизводимый результат нельзя проверить независимо. В медицине то же требование возникает при клинической валидации решения.

Чек-лист перед обучением модели

ПОСТАНОВКА И ДАННЫЕ

1. объект анализа определен;
2. таргет задан правилом: событие, окно, исключения;
3. момент прогноза зафиксирован, у каждого признака есть дата появления;
4. событий на признак не меньше 10-ти;
5. распределения признаков сравнимы с реальным потоком.

РАЗБИЕНИЕ И ПРЕОБРАЗОВАНИЯ

1. разбиение выполнено корректно;
2. тестовый период строго позже обучающего;
3. все преобразования настроены только на обучающей части;
4. целевое кодирование сглажено и посчитано по блокам;
5. качество сопоставлено с отраслевым ориентиром.

ВЫВОД

Пять минут по этому списку экономят недели. Каждый пункт соответствует ошибке, которая не обнаруживается ни одной метрикой качества.

Итоги лекции

1. Обучение формально есть минимизация эмпирического риска; разрыв с истинным риском и называется переобучением.
2. Тип задачи определяет выход модели, функцию потерь и метрику; метка появляется из вероятности только после наложения порога.
3. Объект анализа, единица независимости, целевая переменная и момент прогноза фиксируются до сбора выборки; ошибки здесь моделью не исправляются.
4. Признаки конструируются: агрегаты по окнам, отношения окон, время с события; объём выборки измеряется событиями на признак, а не строками.
5. Разбиение выполняется по единице независимости и по времени; тест используется один раз.
6. Все преобразования обучаются только на обучающей части и применяются единым конвейером.
7. Дисбаланс, смещение выборки и утечка — три причины, по которым отличная на бумаге модель не работает; и они одинаковы в банке, в больнице и в подписочном сервисе.

Вывод

Со следующей лекции начнем разбирать устройство ML-моделей. Первой будет линейная регрессия — самая простая и самая объяснимая из них.