

Национальный исследовательский университет «Высшая школа экономики» · Высшая школа бизнеса

ЛЕКЦИЯ 3

Линейная и логистическая регрессии как базовые модели прогнозирования



Дисциплина «ИИ и машинное обучение» · магистратура «Бизнес-аналитика и цифровые решения в финансах»

1 курс, модули 1–2, 2026/2027 учебный год


План лекции

1. Линейность
2. Линейная регрессия
3. Как подобрать веса
4. Классификация, логистическая регрессия

Где мы в курсе



ответ модели — число на прямой



ответ — по какую сторону прямой объект

Вывод

Обе картинки — одна и та же прямая: слева её спрашивают «сколько?», справа — «да или нет?».

БЛОК 1

Линейность

Что мы называем линейной зависимостью, где она есть, где её нет и почему она бывает спрятана внутри сложных признаков.



Что значит «линейная зависимость»

Линейная зависимость — это **пропорциональная** взаимосвязь между двумя переменными, когда при изменении одной из них другая меняется тоже.

Такси: каждый километр стоит одинаково



Доставка: прибавка меняется скачком



Линейность "поверх" сложных признаков



две новости об одном и том же → одно число «похожесть» → простая прямая даёт ответ

Признаки не обязаны быть измерениями вроде метров и этажей. Часто признак — это результат работы другой модели: набор чисел для текста, для картинки, для клиента. Такие признаки специально учат так, чтобы поверх них хватало простой прямой.

Вывод

Почти любая нейросеть заканчивается линейной моделью: всё, что до неё, — способ получить признаки, в которых ответ линеен.

Где линейности нет



фото: Alvesgaspar / Wikimedia Commons, CC BY-SA 3.0

Для модели фотография — это таблица чисел; сдвинули кадр на одну клетку, и почти все числа стали другими, а ответ «кошка» — нет

Ответ «кошка» не изменился.

А числа изменились почти все:
из 196 клеток другими стали 121,
в красной рамке было 0,34, стало 0,75.

Значит, ответ нельзя получить,
просто взвесив яркости клеток. Нужны
признаки покрупнее — «ухо», «усы», «глаз»;
их выучит нейросеть (тема 9).

Вывод


Линейная модель работает, когда каждый признак в каком-то смысле сам в себе "несёт" часть ответа. Яркость отдельной клетки ответа не несёт: нужны признаки уровня «ухо», «контур», «глаз», и их приходится выучивать. Это граница, за которой начинаются нейросети.

БЛОК 2

Линейная регрессия

Строим модель линейной регрессии. Где она перестаёт работать и как это чинить.

Из чего складывается цена квартиры?



Вклады просто складываются

■	площадь: $60 m^2 \times 0,12$	+7,2
■	этаж: 5-й $\times 0,06$	+0,3
■	до метро: 1 км $\times (-0,4)$	-0,4

вместе признаки дают **7,1 млн Р**

красный вклад вычитается: дальше метро — дешевле
к сумме добавится ещё одно число, одинаковое для всех квартир —
о нём на следующих слайдах

Вес признака — цена одной его единицы: *метр* даёт +0,12 млн, *этаж* +0,06, *километр до метро* -0,4.

ВЫВОД

В случае использования линейной модели предполагается, что вклады признаков **складываются**: цена = вклад *площади* + вклад *метро* + вклад *этажа*.

Линейная модель цены квартиры

$$\begin{array}{ccccccc}
 \text{цена} & = & w_{\text{м}^2} \times \text{площадь} & + & w_{\text{М}} \times \text{близость к метро} & + & w_{\text{этаж}} \times \text{этаж} & + & b \\
 \text{цена} & & \text{площадь} & & \text{близость к метро} & & \text{этаж} & & \text{то, что не зависит от признаков}
 \end{array}$$

Цена — взвешенная сумма признаков: каждый умножаем на свой вес, складываем, прибавляем постоянную часть


Вывод

Это и есть модель *цены* квартиры: три признака, три веса и свободный член. Всё, что она делает — скалярное произведение вектора признаков на вектора весов. Единственный вопрос, которым занимается машинное обучение здесь: **как подобрать веса** на основе имеющихся данных.

Модель линейной регрессии

$$\hat{y} = w_1x_1 + w_2x_2 + w_3x_3 + b$$

x_1 — площадь, x_2 — расстояние до метро, x_3 — этаж; $\hat{y}$ — прогноз цены; w — веса, b — свободный член



$$\hat{y} = 1,5 + 0,12 \cdot \text{площадь}$$

наклон $w = 0,12$ — цена одного метра:

+1 м² к площади — +0,12 млн к цене

сдвиг $b = 1,5$ — «цена нулевой площади»:

земля, подключения, ремонт — то, что есть у любой квартиры

красные отрезки — остатки $e = y - \hat{y}$:

ремонт, вид из окна и торг в признаки не попали,
поэтому точки разбросаны вокруг прямой


Один признак — прямая: наклон w показывает цену метра, сдвиг b — цену «нулевой площади», красные отрезки — остатки

w_j — вес: прибавка к цене за единицу признака при прочих равных — 0,12 млн за м², -0,4 млн за км до метро


b — свободный член: прогноз при нулевых признаках — 1,5 млн, «земля и ремонт»

$e = y - \hat{y}$ — остаток: то, что модель не объяснила — ремонт, вид из окна, торг и т.д.

Границы линейной модели



Цена от расстояния до метро, млн ₽



интервал расстояния — признак «да/нет»: по нему цена снова складывается


Слева надбавка за метро зависит от площади; справа цена падает не по прямой — но если разбить расстояние на интервалы, каждый интервал становится признаком, по которым можно использовать линейную модель

- **вклады складываются:** эффект метро один и тот же для студии и для пентхауса — взаимодействий нет;
- **одна прибавка на всём диапазоне:** метр в 30-метровой и в 200-метровой квартире стоит одинаково;
- **прямая, а не кривая:** цена от метро не должна изменяться нелинейно (соответствует ли реальности?)


Вывод

Изменение **признаков** может помочь остаться в рамках ограничений выше.

Преобразование признаков



прямая не описывает данные




тот же признак в другой шкале — модель осталась линейной

Преобразование	Новый столбец	Когда применимо
Логарифм	$\log(1 + x)$ или $\log y$	Эффект убывает с ростом признака: первые метры важнее последних
Степень	x^2, x^3	Изогнутая зависимость: тормозной путь от скорости
Взаимодействие	$x_1 \cdot x_2$	Эффект признака зависит от другого: у метро метр дороже

Обратная сторона признаков: дубликаты, мультиколлинеарность

Мультиколлинеарность — два признака почти повторяют друг друга. Прогноз в порядке, а веса становятся случайными.

Добавили в таблицу всё, что было под рукой



Данные видят только сумму вкладов



три разных ответа на вопрос «сколько стоит метр» — и все одинаково хороши для прогноза; веса скачут, объяснять бизнесу становится нечего

$$\text{цена} = W_1 \times \text{общая площадь} + W_2 \times \text{до метро, км} + W_3 \times \text{жилая площадь}$$

лишнее слагаемое: этот столбец ничего не добавляет к прогнозу, но забирает себе часть веса у общей площади

Недообучение и переобучение



Одни и те же двенадцать сделок и три модели разной гибкости; справа — их ошибка на этих сделках и на новых

Прямая не улавливает изгибы — **недообучение**. Кривая через каждую точку выучила не рынок, а случайности двенадцати сделок — **переобучение**: следующую квартиру она оценит хуже прямой.

Вывод


Переобучение невидимо на обучающих данных, сверху **правая** модель идеальна; переобучение видно только на отложенных сделках.

БЛОК 3

Как подобрать веса

Чего мы хотим от прямой на уровне математики, как найти минимум производной MSE и определить оптимальные веса

Какая прямая «оптимальная»?



Три прямые на одних и тех же сделках. У каждой свои остатки, и лучшая та, у которой они **в совокупности** меньше всего.


Mean Squared Error (MSE)	Mean Absolute Error (MAE)
$L(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ $= \frac{1}{n} \sum_{i=1}^n (y_i - wx_i - b)^2$	$L(w, b) = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $ $= \frac{1}{n} \sum_{i=1}^n y_i - wx_i - b $

ВЫВОД

Квадрат нужен по двум причинам: остатки бывают разных знаков и гасили бы друг друга, а крупный промах должен стоить дороже — ошибиться на 2 млн в одной сделке хуже, чем на 1 млн в одной из двух.


MSE vs MAE: выбросы

Как растёт штраф с размером ошибки



квадрат растёт быстро: промах 10 млн — это 100 единиц штрафа

Одна странная сделка на 15 квартир



синяя училась с модулем, красная — с квадратом

Квартира	Факт y	Прогноз $\hat{y}$	Для MSE: $(y - \hat{y})^2$	Для MAE: $ y - \hat{y} $
45 м²	7,6	6,6	1,00	1,00
70 м²	9,0	9,7	0,49	0,70
странная сделка, 22 м²	25,0	3,8	449,4	21,2
среднее по трём			MSE = 150,3	MAE = 7,6

Где прямая оптимальна: производная

Вывод · Наклона w и сдвига b для одного признака

$$L(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - wx_i - b)^2$$

ошибка зависит от двух чисел: наклона w и сдвига b . Ищем, при каких значениях она наименьшая

$$\frac{\partial L}{\partial b} = -\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b) = 0 \Rightarrow b =$$

первое условие: сумма остатков равна нулю — прямая обязана пройти через среднюю точку облака точек

Где прямая оптимальна: производная

Вывод · Наклона w и сдвига b для одного признака

$$L(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - wx_i - b)^2$$

ошибка зависит от двух чисел: наклона w и сдвига b . Ищем, при каких значениях она наименьшая

$$\frac{\partial L}{\partial b} = -\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b) = 0 \Rightarrow b = \bar{y} - w\bar{x}$$

первое условие: сумма остатков равна нулю — прямая обязана пройти через среднюю точку облака точек

$$\frac{\partial L}{\partial w} = -\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b) x_i = 0$$

второе условие: остатки не должны быть связаны с признаком, иначе прямую можно ещё подкрутить

$$\Rightarrow w =$$

подставили b и решили: числитель — насколько согласованно *площадь* и *цена* отклоняются от своих средних, знаменатель — разброс *площади*

Где прямая оптимальна: производная

Вывод · Наклона w и сдвига b для одного признака

$$L(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - wx_i - b)^2$$

ошибка зависит от двух чисел: наклона w и сдвига b . Ищем, при каких значениях она наименьшая

$$\frac{\partial L}{\partial b} = -\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b) = 0 \Rightarrow b = \bar{y} - w\bar{x}$$

первое условие: сумма остатков равна нулю — прямая обязана пройти через среднюю точку облака точек

$$\frac{\partial L}{\partial w} = -\frac{2}{n} \sum_{i=1}^n (y_i - wx_i - b) x_i = 0$$

второе условие: остатки не должны быть связаны с признаком, иначе прямую можно ещё подкрутить

$$\Rightarrow w = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$


подставили b и решили: числитель — насколько согласованно *площадь* и *цена* отклоняются от своих средних, знаменатель — разброс *площади*

Вывод


Читаем ответ словами: **сдвиг** держит прямую на средней высоте, а **наклон** тем больше, чем сильнее *цена* меняется вместе с *площадью*, и тем меньше, чем шире разброс самих *площадей*. Для нескольких признаков это превращается в систему из нескольких таких уравнений.

Градиентный спуск

Спуск в тумане: всей чаши не видно



То же на кривой ошибки



щупаем склон под ногами и делаем шаг вниз; у дна склон пологий — шаги сами укорачиваются

шаг = $\eta \cdot$ (наклон кривой в этой точке): круче склон — длиннее шаг

Туман — это и есть наша ситуация: всей чаши не видно, известен только наклон под ногами; зелёная стрелка справа — длина одного шага

ВЫВОД · ШАГА ГРАДИЕНТНОГО СПУСКА

$w^{(0)}$ — начальное приближение нули или малые случайные числа; верхний индекс в скобках — номер шага

$$w^{(t+1)} = w^{(t)} - \eta \frac{dL}{dw}(w^{(t)})$$

та же производная, что и на прошлом слайде, но не приравненная к нулю: считаем её в текущей точке


шаг против производной; η — длина шага: мала — ползём, велика — перепрыгиваем дно

Весов обычно несколько — тогда эта строка пишется для каждого веса отдельно.

Что происходит с весами при переобучении?



кривая проходит через все точки
и мечется между ними



■ без штрафа ■ со штрафом

чтобы так изгибаться, весам приходится быть огромными



точки задеты не все, зато форма
верная — и на новых сделках лучше

Чтобы кривая так металась, весам приходится быть огромными; нужно как-то ограничивать веса!


$$L_2 = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j w_j^2$$

$$L_1 = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j |w_j|$$

к ошибке добавили плату за размер весов; λ — подбирается по отложенным данным

Что видно в данных	Штраф	Что получаем
Признаки повторяют друг друга	L_2	Веса малы и устойчивы
Кандидатов сотни, важны лишь десятки	L_1	Слабые веса равно нули — отбор признаков

Как оценить качество линейной регрессии



- **серые отрезки** — весь разброс цен: насколько цены отличаются от среднего константного предсказания;
- **красные отрезки** — то, что осталось необъяснённым линейной регрессией.

$$R^2 = 1 - \frac{\text{предсказание регрессии}}{\text{предсказание константой}}$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

у каждой сделки два отрезка: серый — до средней цены, красный — до прямой

Задача	Типичный R²	Почему
Растяжение пружины от груза	0,99	физический закон, шум только от прибора
Цена квартиры	0,6–0,8	ремонт, вид, торг в признаки не попадают
Опоздание автобуса на рейсе	0,05	решают пробки и светофоры; но и это ценно для расписания

Другие функции потерь



Форма штрафа — это условие задачи: что считать крупным промахом и одинаково ли дороги промахи вверх и вниз

- **Huber** — квадрат рядом с нулём, модуль вдали: гладкая, как MSE, и устойчивая к выбросам, как MAE;
- **квантильная** — несимметричная: недопрогноз и перепрогноз стоят по-разному; так планируют наличные в банкомате, где «не хватило» дороже, чем «лишние»;
- **логарифм ответа** — ошибка в процентах, а не в миллионах: когда промах на миллион в дешёвой и в дорогой квартире — разные вещи.

Вывод

Функция потерь — не техническая деталь, а формулировка того, что для бизнеса «плохо». Разберём на семинаре: одна и та же модель с разными функциями потерь даёт разные прямые.

БЛОК 4

Классификация, логистическая регрессия

Предсказываем «да или нет» с тем же набором признаков: разделяющая прямая, вероятность через сигмоиду, правдоподобие и метрики.

Та же объект, но теперь другой вопрос про него




Признаки те же, что и в задаче о цене. Ответ теперь не число, а факт: *продалась квартира за месяц или нет*. Ошибка измеряется не «на сколько промахнулись», а «угадали или нет» — и, как увидим, ещё «насколько были уверены».

Вывод

Модель классификации почти никогда не выдаёт «да» или «нет». Она выдаёт **число**, а ответ появляется потом, после сравнения с порогом.

Разделяющая прямая

до метро, км



чёрная точка легла у самой границы — там ответ модели самый неуверенный


$$z = w_1x_1 + w_2x_2 + b$$

та же взвешенная сумма, что и в регрессии; теперь смотрим на её знак

- $z > 0$ — модель отвечает «продается за 30 дней»;
- $z < 0$ — «не продается»;
- $z = 0$ — сама граница, прямая на картинке.

Знак z говорит, по какую сторону от прямой лежит точка, а $|z|$ — как далеко она от границы.

Три признака — разделяющая плоскость



Добавили этаж: граница из прямой стала плоскостью; зелёные точки лежат над ней, красные — под ней.

$$z = w_1x_1 + w_2x_2 + w_3x_3 + b$$

над плоскостью $z > 0$: продается

под плоскостью $z < 0$: не продается


красные точки лежат под плоскостью
и потому видны сквозь неё бледнее;
пунктир — насколько ответ уверенный

в четырёх признаках картинка уже нет,
а формула и смысл те же

$$z = w^T x + b = w_1x_1 + \dots + w_dx_d + b$$

в d признаках граница $z = 0$ — плоскость $d+1$ -мерном пространстве, а не трехмерном как на картинке выше, но формула и смысл те же: **знак** z — сторона, $|z|$ — **расстояние** до плоскости

Преобразование признаков



Слева классы вложены друг в друга, никакая прямая их не разделит; добавили признак «расстояние от центра» — и разделить прямой можно


$$z = w_1x_1 + w_2x_2 + w_3(x_1^2 + x_2^2) + b$$

новый столбец в таблице признаков — квадрат расстояния от центра; в новых координатах граница — прямая, в старых — окружность

Вывод


Тот же приём, что и в регрессии: **модель не меняем, меняем признаки**. Растянули и перенесли точки так, чтобы классы разошлись, — и линейный классификатор справился. Нейросети делают ровно это, только растяжение выучивают сами.

Логистическая регрессия: вероятность как оценка принадлежности к классу



пунктиры: балл по горизонтали → вероятность на оси от 0 до 1

$\hat{p}$ — вероятность «продать» — число со смыслом «доля», значит его можно умножать на деньги и рассуждать в бизнес терминах.




$$\hat{p} = \sigma(z) = \frac{1}{1 + e^{-z}}, z = w^T x + b$$

при большом z экспонента почти ноль и $\hat{p} \approx 1$, при большом отрицательном — $\hat{p} \approx 0$, при $z = 0$ ровно 0,5

Почему MSE для классификации плох?

Квартира продалась. Какой шанс на это давала модель заранее?



Слева направо шанс падает в **4 000** раз, а MSE растет всего в **2,8** раза и упирается в потолок.

штраф MSE считается как $(1 - \hat{p})^2$ — у него есть потолок: больше единицы он не станет никогда

Вывод

У квадрата ошибки **есть потолок**: и вероятность, и само значение MSE лежат между нулём и единицей, поэтому больше единицы штраф не станет. Уверенная чушь стоит почти столько же, сколько осторожное сомнение, — и обучению нечем их различать. Нужна мера ошибки, которая за уверенную ошибку берёт сколь угодно много.

LogLoss или логистические потери



факт: продана ($y = 1$)
модель: $\hat{p} = 0,9$

множитель $\hat{p} = 0,9$



факт: не продана ($y = 0$)
модель: $\hat{p} = 0,3$

множитель $1 - \hat{p} = 0,7$



факт: продана ($y = 1$)
модель: $\hat{p} = 0,8$

множитель $\hat{p} = 0,8$



факт: не продана ($y = 0$)
модель: $\hat{p} = 0,6$

множитель $1 - \hat{p} = 0,4$

$L = 0,9 \cdot 0,7 \cdot 0,8 \cdot 0,4 = 0,20$ — насколько правдоподобна вся выборка при этих весах; чем хуже вероятности, тем меньше произведение

Четыре квартиры: для проданной в правдоподобие идёт $\hat{p}$, для непроданной — $1 - \hat{p}$; хорошие веса делают произведение большим

ВЫВОД ЛОГИСТИЧЕСКИХ ПОТЕРЬ ИЗ МЕТОДА МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ ДЛЯ РАСПРЕДЕЛЕНИЯ БЕРНУЛЛИ

$p(y_i | x_i) = p_i^{y_i}(1 - p_i)^{1-y_i}$ одна формула для обоих исходов: при $y = 1$ остаётся p , при $y = 0$ — $(1 - p)$;

$\mathcal{L}(w) = \prod_{i=1}^n p_i^{y_i}(1 - p_i)^{1-y_i}$ правдоподобие выборки — произведение по квартирам: сделки **независимы**

$\log \mathcal{L}(w) =$

LogLoss или логистические потери



факт: продана ($y = 1$)
модель: $\hat{p} = 0,9$

множитель $\hat{p} = 0,9$



факт: не продана ($y = 0$)
модель: $\hat{p} = 0,3$

множитель $1 - \hat{p} = 0,7$



факт: продана ($y = 1$)
модель: $\hat{p} = 0,8$

множитель $\hat{p} = 0,8$



факт: не продана ($y = 0$)
модель: $\hat{p} = 0,6$

множитель $1 - \hat{p} = 0,4$

$L = 0,9 \cdot 0,7 \cdot 0,8 \cdot 0,4 = 0,20$ — насколько правдоподобна вся выборка при этих весах; чем хуже вероятности, тем меньше произведение

Четыре квартиры: для проданной в правдоподобие идёт $\hat{p}$, для непроданной — $1 - \hat{p}$; хорошие веса делают произведение большим

ВЫВОД ЛОГИСТИЧЕСКИХ ПОТЕРЬ ИЗ МЕТОДА МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ ДЛЯ РАСПРЕДЕЛЕНИЯ БЕРНУЛЛИ

$p(y_i | x_i) = p_i^{y_i} (1 - p_i)^{1-y_i}$ одна формула для обоих исходов: при $y = 1$ остаётся p , при $y = 0$ — $(1 - p)$;

$\mathcal{L}(w) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}$ правдоподобие выборки — произведение по квартирам: сделки **независимы**

$\log \mathcal{L}(w) = \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$ логарифм: произведение стало суммой, степени — множителями; где был максимум, там и остался

$\ell(w) = -\frac{1}{n} \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)] \rightarrow \min$ минус и среднее: максимум правдоподобия превратился в минимум ошибки — это и есть *логистические потери*

Главный вопрос: «**при каких весах то, что случилось, наиболее вероятно?**». Ответ: при таких, которые минимизируют $\ell(w)$

Итоги лекции

1. Линейность — это пропорциональная взаимосвязь между двумя переменными, когда при изменении одной из них другая меняется тоже.
2. Линейная модель — скалярное произведение вектора признаков на вектора весов.
3. Веса подбирают, минимизируя среднюю квадратичную ошибку.
4. Дубликаты признаков и «усложнение» признаков дают большие неустойчивые веса; регуляризация помогает бороться с большими весами.
5. Классификация — та же прямая, которая разделяет разные классы.

ЗАКЛЮЧЕНИЕ

Следующая лекция: модели, которые находят взаимодействия и изгибы сами, — деревья решений и случайный лес.