

Национальный исследовательский университет «Высшая школа экономики» · Высшая школа бизнеса

ЛЕКЦИИ 5–6

Решающие деревья, случайный лес и градиентный бустинг


Дисциплина «ИИ и машинное обучение» · магистратура «Бизнес-аналитика и цифровые решения в финансах»

1 курс, модули 1–2, 2026/2027 учебный год

План лекции

1. Решающие деревья
2. Ошибка, бэггинг и случайный лес
3. Градиентный бустинг
4. Библиотеки бустинга

Продолжаем: от прямой к деревьям



Мы по-прежнему на шаге «Модель»: после линейных моделей — деревья и ансамбли из них

Блок 1 · Дерево



Блок 2 · Случайный лес



Блоки 3–4 · Бустинг



Три идеи двух пар: одно дерево, лес из независимых деревьев, бустинг — деревья по очереди

Вывод


Линейная модель складывает вклады признаков. Дерево задаёт вопросы «да/нет» и само находит пороги и взаимодействия. А из сотен деревьев собирают самые сильные модели.

БЛОК 1

Решающие деревья

Как дерево решает и как его обучают: алгоритм, выбор вопроса, критерий останова. Связь с линейными моделями и почему одно дерево неустойчиво.


Дерево — серия вопросов



Экзаменатор задаёт вопрос, по ответу выбирает следующий, а в конце ставит оценку

Решающее дерево — вопросы «да/нет» о признаках, выстроенные в дерево: в узлах — вопросы, в листьях — готовые ответы. Вопрос почти всегда простой: «признак меньше порога?».

Как дерево делит пространство



Два вопроса — четыре листа — четыре прямоугольника; буквы связывают лист с его областью



ВЫВОД


Каждый вопрос режет по одному признаку — области прямоугольные. Взаимодействия дерево находит само.

Алгоритм обучения дерева

1. Все объекты обучающей выборки кладём в корень.
2. Если сработал **критерий останова** — узел становится листом. Ответ листа: среднее или самый частый класс.
3. Иначе перебираем все признаки и все пороги и берём вопрос «признак < порог?», который делит лучше всех.
4. Делим объекты узла на две части по этому вопросу.
5. Повторяем шаги 2–4 для каждой части. Выбранный вопрос не пересматриваем — алгоритм **жадный**.

Алгоритм обучения дерева

Признак «до метро»: 12 квартир по возрастанию расстояния



ошибок, если по обе стороны порога ответить большинством

Шаг 3 на примере: для каждого порога считаем качество разреза; лучший вопрос из всех признаков встаёт в узел

То же — для каждого признака

до метро	1,8 км	2 ош.
----------	--------	-------

цена к рынку	+3 %	3 ош.
--------------	------	-------

этаж	4	5 ош.
------	---	-------


площадь	48 м ²	4 ош.
---------	-------------------	-------

побеждает лучший вопрос из всех —
он и встаёт в узел

1. Все объекты обучающей выборки кладём в корень.
2. Если сработал **критерий останова** — узел становится листом. Ответ листа: среднее или самый частый класс.
3. Иначе перебираем все признаки и все пороги и берём вопрос «признак < порог?», который делит лучше всех.
4. Делим объекты узла на две части по этому вопросу.
5. Повторяем шаги 2–4 для каждой части. Выбранный вопрос не пересматриваем — алгоритм **жадный**.

Алгоритм обучения дерева

Признак «до метро»: 12 квартир по возрастанию расстояния



Шаг 3 на примере: для каждого порога считаем качество разреза; лучший вопрос из всех признаков встаёт в узел

То же — для каждого признака

до метро	1,8 км	2 ош.
----------	--------	-------

цена к рынку	+3 %	3 ош.
--------------	------	-------

этаж	4	5 ош.
------	---	-------


площадь	48 м ²	4 ош.
---------	-------------------	-------

побеждает лучший вопрос из всех —
он и встаёт в узел

1. Все объекты обучающей выборки кладем в корень.
2. Если сработал **критерий останова** — узел становится листом. Ответ листа: среднее или самый частый класс.
3. Иначе перебираем все признаки и все пороги и берём вопрос «признак < порог?», который делит лучше всех.
4. Делим объекты узла на две части по этому вопросу.
5. Повторяем шаги 2–4 для каждой части. Выбранный вопрос не пересматриваем — алгоритм **жадный**.

Алгоритм обучения дерева

Признак «до метро»: 12 квартир по возрастанию расстояния



Шаг 3 на примере: для каждого порога считаем качество разреза; лучший вопрос из всех признаков встаёт в узел

То же — для каждого признака

до метро	1,8 км	2 ош.
----------	--------	-------

цена к рынку	+3 %	3 ош.
--------------	------	-------

этаж	4	5 ош.
------	---	-------


площадь	48 м ²	4 ош.
---------	-------------------	-------

побеждает лучший вопрос из всех — он и встаёт в узел

1. Все объекты обучающей выборки кладем в корень.
2. Если сработал **критерий останова** — узел становится листом. Ответ листа: среднее или самый частый класс.
3. Иначе перебираем все признаки и все пороги и берём вопрос «признак < порог?», который делит лучше всех.
4. Делим объекты узла на две части по этому вопросу.
5. Повторяем шаги 2–4 для каждой части. Выбранный вопрос не пересматриваем — алгоритм **жадный**.

Алгоритм обучения дерева

Признак «до метро»: 12 квартир по возрастанию расстояния



Шаг 3 на примере: для каждого порога считаем качество разреза; лучший вопрос из всех признаков встает в узел

То же — для каждого признака

до метро	1,8 км	2 ош.
----------	--------	-------

цена к рынку	+3 %	3 ош.
--------------	------	-------

этаж	4	5 ош.
------	---	-------


площадь	48 м ²	4 ош.
---------	-------------------	-------

побеждает лучший вопрос из всех —
он и встает в узел

1. Все объекты обучающей выборки кладем в корень.
2. Если сработал **критерий останова** — узел становится листом. Ответ листа: среднее или самый частый класс.
3. Иначе перебираем все признаки и все пороги и берем вопрос «признак < порог?», который делит лучше всех.
4. Делим объекты узла на две части по этому вопросу.
5. Повторяем шаги 2–4 для каждой части. Выбранный вопрос не пересматриваем — алгоритм **жадный**.

Как выбрать вопрос

Насколько перемешаны ответы в листе



все одного цвета — 0; поровну — максимум

Хаотичность листа — насколько плохо его ответы описывает одно число. Хороший вопрос сильнее всего снижает хаотичность; каждая часть весит столько, сколько в ней объектов.

Задача	Мера хаотичности	Словами
Регрессия	дисперсия	насколько ответы в листе разбросаны вокруг среднего
Классификация	Джини	как часто ошибёмся, угадывая класс наугад по долям листа
Классификация	энтропия	то же по смыслу; ноль — все одного класса, максимум — поровну

Как выбрать вопрос




Вопрос А разделил дома почти по цвету — перемешанность упала; вопрос Б ничего не изменил

Хаотичность листа — насколько плохо его ответы описывает одно число. Хороший вопрос сильнее всего снижает хаотичность; каждая часть весит столько, сколько в ней объектов.

Задача	Мера хаотичности	Словами
Регрессия	дисперсия	насколько ответы в листе разбросаны вокруг среднего
Классификация	Джини	как часто ошибёмся, угадывая класс наугад по долям листа
Классификация	энтропия	то же по смыслу; ноль — все одного класса, максимум — поровну


Останов, стрижка, пропуски, категории



Одни и те же 70 квартир с шумом; доли ошибок посчитаны на 4 000 новых квартирах

- **Останов** — главная ручка сложности: предел глубины, минимум объектов в листе, предел числа листьев.
- **Стрижка**: вырастить большое дерево и срезать ветки, которые не окупают плату за лист.
- **Пропуски**: при выборе вопроса объекты с пропуском не учитывают, при прогнозе ведут в обе ветки.
- **Категории**: упорядочить значения по доле класса или среднему ответу и резать как число.

Дерево — линейная модель над областями



Новые признаки «попал в лист?» и веса

		в A	в B	в C	в D	прогноз
квартира	①	1	0	0	0	0,92
квартира	②	0	0	0	1	0,14
квартира	③	0	0	1	0	1
вес листа w		0,92	0	1	0,14	

прогноз =
сумма «признак × вес»
по всем листьям —
та же линейная
модель, что в лекции 3

вес листа — доля проданных среди обучающих квартир, попавших в этот лист

Те же четыре листа, что на слайде с квартирами; три квартиры попали в разные листья


линейная модель: $\hat{y} = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$

дерево: $a(x) = w_1 [x \in R_1] + \dots + w_J [x \in R_J] = \sum_{j=1}^J w_j [x \in R_j]$

R_j — область листа j ; $[x \in R]$ — признак «объект попал в лист j »: 1 или 0; w_j — ответ листа; J — число листьев

Вывод
Дерево само придумывает признаки — области, — а над ними строит обычную линейную модель.

Чего одно дерево не умеет



Синие ступеньки — средние в листьях; за 2025 годом дерево повторяет последний лист

В регрессии ответ дерева — ступеньки: в каждом листе одно число. За краем данных объект попадает в крайний лист.

- внутри данных ступеньки повторяют любую форму;
- за краем данных — горизонталь: тренд дерево не продолжит;
- чуть другие данные — другие вопросы и другое дерево.

Вывод

Неустойчивость — главная причина собирать деревья в ансамбли.

БЛОК 2

Ошибка, бэггинг и случайный лес

Из чего складывается ошибка модели. Почему усреднение многих деревьев гасит разброс и как устроен случайный лес.

Из чего складывается ошибка



Разложение ошибки словами: верно для квадратичной ошибки, по смыслу — и для других




Каждая точка — модель, обученная на своей выборке; центр мишени — лучший возможный ответ


Вывод

Простые модели — большое смещение и малый разброс, сложные — наоборот. Шум не убирает никто.


Простые и сложные модели



смещение велико, разброс мал



смещение заметно, разброс мал



смещения нет, разброс велик

--- истина — модели на 15 разных выборках — их среднее

Спрос на мороженое по месяцам; 15 выборок по 30 точек, на каждой обучена своя модель

Вывод

Глубокое дерево в среднем угадывает волну, но каждое ошибается по-своему. Если усреднить много таких деревьев, разброс уйдёт, а смещение останется малым.

Бэггинг: бутстрап и усреднение


Бутстрап: тянем с возвращением



1:	1	1	3	4	4	6	7	8	нет: 2, 5
2:	2	2	3	5	6	6	7	8	нет: 1, 4
3:	1	3	3	3	5	6	7	7	нет: 2, 4, 8


у каждого дерева своя выборка

Одно глубокое дерево



разброс велик

Среднее 60 деревьев



смещение то же, разброс меньше


Слева — как получить разные выборки из одной; справа — что даёт усреднение 60 глубоких деревьев

- **Бутстрап:** из выборки тянем столько же объектов с возвращением — повторы есть, части объектов нет.
- **Бэггинг:** на каждой такой выборке своё глубокое дерево, ответы усредняем.

$$a(x) = \frac{1}{N} \sum_{n=1}^N b_n(x), \quad \text{ошибка}(a) = \frac{1}{N} \cdot \text{средняя ошибка одной модели}$$

если ошибки моделей в среднем нулевые и не связаны между собой; ошибка — средний квадрат отклонения от верного ответа

Случайный лес




Слева — формула ниже в виде кривых: сколько разброса остаётся при разной похожести деревьев

$$\frac{\text{разброс леса}}{\text{разброс одного дерева}} = \rho + \frac{1 - \rho}{N}$$

ρ — похожесть (корреляция) ответов двух деревьев: 0 — независимы, 1 — одинаковы; N — число деревьев

1. Каждое дерево учится на своей бутстрап-выборке.
2. В каждом узле вопрос ищут среди случайных m признаков: корень из их числа для классов, треть — для регрессии.
3. Деревья растут глубокими, ответы усредняют, а в классификации — голосуют.

Случайный лес




Слева — формула ниже в виде кривых: сколько разброса остаётся при разной похожести деревьев

$$\frac{\text{разброс леса}}{\text{разброс одного дерева}} = \rho + \frac{1 - \rho}{N}$$

ρ — похожесть (корреляция) ответов двух деревьев: 0 — независимы, 1 — одинаковы; N — число деревьев

1. Каждое дерево учится на своей бутстрап-выборке.
2. В каждом узле вопрос ищут среди случайных m признаков: корень из их числа для классов, треть — для регрессии.
3. Деревья растут глубокими, ответы усредняют, а в классификации — голосуют.

Случайный лес




Слева — формула ниже в виде кривых: сколько разброса остаётся при разной похожести деревьев

$$\frac{\text{разброс леса}}{\text{разброс одного дерева}} = \rho + \frac{1 - \rho}{N}$$

ρ — похожесть (корреляция) ответов двух деревьев: 0 — независимы, 1 — одинаковы; N — число деревьев

1. Каждое дерево учится на своей бутстрап-выборке.
2. В каждом узле вопрос ищут среди случайных m признаков: корень из их числа для классов, треть — для регрессии.
3. Деревья растут глубокими, ответы усредняют, а в классификации — голосуют.

Случайный лес



Слева — формула ниже в виде кривых: сколько разброса остаётся при разной похожести деревьев

$$\frac{\text{разброс леса}}{\text{разброс одного дерева}} = \rho + \frac{1 - \rho}{N}$$

ρ — похожесть (корреляция) ответов двух деревьев: 0 — независимы, 1 — одинаковы; N — число деревьев

В каждом узле — своя лотерея признаков

узел 1	площадь	до метро	этаж
	цена к рынку	год	район
	ремонт	балкон	парковка
узел 2	площадь	до метро	этаж
	цена к рынку	год	район
	ремонт	балкон	парковка

лучший вопрос ищут только среди трёх выпавших —
деревья выходят разными

1. Каждое дерево учится на своей бутстрап-выборке.
2. В каждом узле вопрос ищут среди случайных m признаков: корень из их числа для классов, треть — для регрессии.
3. Деревья растут глубокими, ответы усредняют, а в классификации — голосуют.

БЛОК 3

Градиентный бустинг

Модели строятся по очереди, и каждая исправляет ошибки суммы предыдущих. Остатки, сдвиги, алгоритм в формулах, темп обучения и почему в бустинге деревья неглубокие.

Идея бустинга

Как в лесу: каждый учит всё сам

	линейные	деревья	ансамбли	метрики
студент 1				
студент 2				
студент 3				

у каждого пробелы в своём месте,
а «линейные» выучили все трое

Как в бустинге: по очереди

	линейные	деревья	ансамбли	метрики
студент 1				
студент 2				
студент 3				
команда				

каждого следующего учат тому, чего команда ещё не знает


Слева — как учится лес: все учат всё; справа — бустинг: каждого учат тому, чего команда ещё не знает

лес:
$$a(x) = \frac{1}{N} \sum_{n=1}^N b_n(x)$$

бустинг:
$$a_N(x) = b_0(x) + b_1(x) + \dots + b_N(x)$$

в лесу модели учатся независимо и усредняются; в бустинге — по очереди, и каждая следующая исправляет ошибки суммы предыдущих

Бустинг на остатках





60 месяцев продаж мороженого; деревья глубины 2, каждое прибавляется с множителем 0,3

$$s_i = y_i - a_{N-1}(x_i), \quad \sum_{i=1}^{\ell} (b_N(x_i) - s_i)^2 \rightarrow \min, \quad a_N(x) = a_{N-1}(x) + b_N(x)$$



остаток s_i — факт минус прогноз текущей суммы; новое дерево b_N учится предсказывать остатки на ℓ обучающих объектах и прибавляется к сумме

Сдвиги: куда двигать прогноз



Ошибка одного объекта как функция добавки к его текущему прогнозу; точка — где мы сейчас

Сдвиги: куда двигать прогноз



Ошибка одного объекта как функция добавки к его текущему прогнозу; точка — где мы сейчас

$$s_i = - \frac{\partial L(y_i, a_{N-1}(x_i))}{\partial a_{N-1}(x_i)}$$

сдвиг — наклон функции ошибки L по прогнозу в текущей точке, взятый с минусом

- Квадрат ошибки: сдвиг — остаток $y - a(x)$. Модуль ошибки: только знак остатка.
- Классификация, логистическая ошибка: сдвиг $y - p$ — факт (0 или 1) минус вероятность.

Спуск по прогнозам



Два обучающих объекта: оси — их прогнозы; кольца — уровни общей ошибки

Сдвиги всех объектов вместе — направление, в котором общая ошибка падает быстрее всего. Бустинг — градиентный спуск, только шагают не веса, а сами прогнозы.

- шаг делает дерево, а оно повторяет направление неточно — путь идёт зигзагом;
- дерево нужно, чтобы поправка дошла до новых объектов;
- построенные деревья не меняют: бустинг жадный.

Алгоритм градиентного бустинга

АЛГОРИТМ · ГРАДИЕНТНЫЙ БУСТИНГ

$$a_0(x) = \text{константа}$$

Старт: среднее ответов в регрессии, доля класса в классификации.

$$s_i = -\frac{\partial L(y_i, a_{n-1}(x_i))}{\partial a_{n-1}(x_i)}$$

Сдвиг каждого обучающего объекта: куда и насколько двигать его прогноз.

$$\sum_{i=1}^{\ell} (b_n(x_i) - s_i)^2 \rightarrow \min$$

Новое дерево учится предсказывать сдвиги — всегда по квадратичной ошибке.

$$a_n(x) = a_{n-1}(x) + \eta b_n(x)$$

Прибавляем дерево с множителем η — темпом обучения, например 0,1.


Шаги 2–4 повторяем для $n = 1, 2, \dots, N$; число деревьев N выбирают по валидации.

Задача	Функция ошибки	Сдвиг s_i	Старт a_0
Регрессия	квадрат отклонения	остаток $y - a(x)$	среднее ответов
Регрессия с выбросами	модуль отклонения	знак остатка: +1 или -1	медиана ответов
Классификация	логистическая	$y - p$: факт минус вероятность	доля класса

ВЫВОД

Вся информация о функции ошибки сидит в сдвигах. Поэтому один и тот же алгоритм решает и регрессию, и классификацию, и задачу со своей функцией ошибки — меняется только формула сдвига.

Темп обучения и число деревьев



120 месяцев для обучения, 400 новых; деревья глубины 2; посчитано, а не нарисовано


$$a_N(x) = a_{N-1}(x) + \eta b_N(x), \quad 0 < \eta \leq 1$$

η — темп обучения: какую долю нового дерева прибавляем

- **Шаг:** η , например 0,1. Меньше шаг — больше деревьев, обычно лучше.
- **Число деревьев:** на новых данных ошибка после минимума растёт — стоп по валидации.
- **Подвыборки:** каждое дерево — на случайной половине данных.

Бустинг над деревьями

Каркас — от дерева, обученного на сдвигах



числа в листьях — заново, под настоящую ошибку

Разбиения дерева остаются, числа в листьях подбираются под исходную функцию ошибки

$$\gamma_j = \arg \min_{\gamma} \sum_{x_i \in R_j} L(y_i, a_{N-1}(x_i) + \gamma)$$

число в листе j подбирают под исходную ошибку, каждый лист отдельно

- В бустинге деревья неглубокие, 3–6 уровней: бустинг снижает смещение, а разброс с каждым деревом растёт.


	Случайный лес	Градиентный бустинг
Деревья	глубокие, учатся независимо	неглубокие, строятся по очереди
Что снижает	разброс: усреднение	смещение: сумма поправок
Больше деревьев	не вредит	после минимума — переобучение

БЛОК 4

Библиотеки бустинга

Почему реализаций бустинга много — XGBoost, LightGBM, CatBoost — и какую выбрать.

Почему бустингов много



Ядро у всех одно — градиентный бустинг над деревьями; каждая реализация добавила своё

Задача	Что брать
Много категориальных признаков, нужен хороший результат без долгой настройки	CatBoost
Миллионы строк и сотни признаков, важна скорость обучения	LightGBM
Проверенный стандарт: пропуски, разреженные данные, большое сообщество	XGBoost
Учебная или небольшая задача, всё в одной библиотеке	scikit-learn: HistGradientBoosting

Вывод

Алгоритм у всех один — отличается инженерия. После настройки качество обычно близкое: сравнивайте на валидации.

Итоги двух пар

Модель	Как устроена	Сильная сторона	Слабая сторона
Линейная	взвешенная сумма признаков	быстрая, понятная	только линейные связи
Решающее дерево	вопросы «да/нет», в листе ответ	само находит пороги и взаимодействия	неустойчиво, переобучается, нет тренда
Случайный лес	среднее глубоких разных деревьев	почти без настройки, кросс-валидация	долго учится, чуть слабее бустинга
Градиентный бустинг	деревья по очереди исправляют ошибки	обычно самый точный на таблицах	надо подбирать шаг и число деревьев

Вывод

Ошибка = шум + смещение + разброс. Лес гасит разброс глубоких деревьев, бустинг снижает смещение неглубоких. На практике бустинг берут готовым: CatBoost, LightGBM или XGBoost.