Национальный исследовательский университет «Высшая школа экономики» · Высшая школа бизнеса

ЛЕКЦИИ 7–8

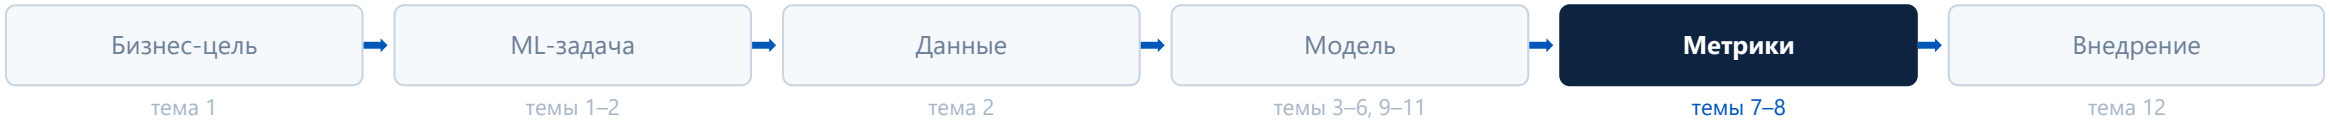
Метрики качества и интерпретация ML-моделей

Дисциплина «ИИ и машинное обучение» · магистратура «Бизнес-аналитика и цифровые решения в финансах»
1 курс, модули 1–2, 2026/2027 учебный год

План лекции

1. Метрики качества моделей и их связь с бизнес-результатом
2. Интерпретируемость ML-моделей

Продолжаем: от обученной модели к решению



Оценить

Какие ошибки допускает модель?

Объяснить

На какие признаки опирается прогноз?

Проверить

Сохранится ли качество в новых условиях?

ВЫВОД

Одна метрика не заменяет проверку порога, данных и условий применения.

БЛОК 1

Метрики качества моделей и их связь с бизнес-результатом

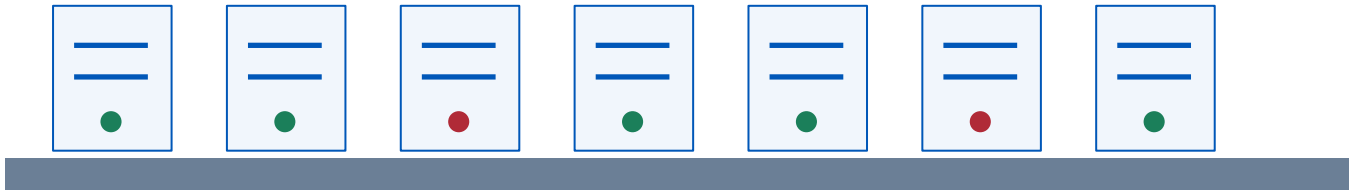
Порог, ошибки, качество классификации и регрессии.

Оценка модели и решение — разные величины

Модель оценивает вероятность дефекта p(x). Порог t превращает эту оценку в действие: изделие отправляют на проверку, если p(x) не меньше t.

$$\hat{y} = \begin{cases} 1, & p(x) \geq t, \\ 0, & p(x) < t. \end{cases}$$

ŷ = 1 — проверить изделие; ŷ = 0 — не проверять. p(x) — оценка модели, t — выбранный порог.



Изделия на линии → признаки → оценка дефекта

Вероятность 0,72

Порог 0,50:
проверить изделие

ВЫВОД
Один и тот же прогноз можно превратить в разные решения, меняя порог и допустимую нагрузку на проверку.

Матрица ошибок: считаем четыре исхода

Матрица сопоставляет реальное состояние изделия и решение модели. В проверке 1000 изделий: 20 дефектных и 980 исправных.

	Прогноз: дефект	Прогноз: исправно
Факт: дефект	TP = 16	FN = 4
Факт: исправно	FP = 40	TN = 940

$$n = TP + FN + FP + TN = 16 + 4 + 40 + 940 = 1000$$

TP — найденный дефект; FN — пропуск; FP — ложная тревога; TN — верно распознанное исправное изделие.

$$n_+ = TP + FN = 20, \qquad n_- = FP + TN = 980$$

n_+ — число дефектных; n_- — число исправных изделий.

ВЫВОД

Матрица ошибок соответствует конкретному порогу, выборке и определению события. Без этих условий числа нельзя корректно сравнить с другой моделью. Ключевой вопрос — какие последствия имеют именно FP и FN в рассматриваемом процессе.

Precision и recall отвечают на разные вопросы

Precision (точность положительных ответов) — доля дефектов среди отправленных на проверку. Recall (полнота) — доля найденных дефектов среди всех действительно дефектных изделий.

$$Precision = \frac{TP}{TP + FP}, \quad Recall = \frac{TP}{TP + FN},$$

$$FPR = \frac{FP}{FP + TN}, \quad TPR = \frac{TP}{TP + TN}$$

TPR — доля найденных дефектов среди всех дефектных; FPR — доля исправных, ошибочно отправленных на проверку.



ВЫВОД

Высокий recall сокращает пропуски. Высокий precision уменьшает долю лишних проверок; оба показателя нужны вместе.

Accuracy и F1: что скрывает одно число

Accuracy считает все верные ответы; при редком дефекте она бывает высокой даже у модели, которая пропускает каждый дефект.

$$\text{Accuracy} = \frac{TP + TN}{n};$$

$$F_1 = \frac{2}{\left(\frac{1}{P} + \frac{1}{R}\right)} = \frac{2PR}{P + R}; \quad F_\beta = \frac{(1 + \beta^2)PR}{\beta^2 P + R}$$

Для модели: accuracy = 956/1000 = 95,6 %; $F_1 \approx 0{,}421$. При $\beta = 1$ получаем F_1.



F1 высок, когда и precision, и recall высоки: слабый из двух показателей сильно снижает их гармоническое среднее. Fβ — та же сводка с настраиваемым приоритетом: β > 1 усиливает роль полноты, β < 1 — точности положительных решений.

ВЫВОД

F_β — гармоническая сводка precision и recall. При β > 1 сильнее важна полнота, при β < 1 — точность положительных решений.

Порог меняет число пропусков

Для одной модели сравним три порога на той же выборке. Снижение порога расширяет множество проверяемых изделий: recall не уменьшается, а precision может меняться немонотонно.

	TP / FP	Проверок	Precision	Recall
t = 0,20	18 / 98	116	15,5 %	90 %
t = 0,50	16 / 40	56	28,6 %	80 %
t = 0,80	10 / 10	20	50 %	50 %

ВЫВОД

При снижении порога TP и FP не уменьшаются, FN и TN не увеличиваются. Recall не уменьшается. Precision может вырасти или снизиться: всё зависит от доли дефектов среди новых выбранных изделий. Его плавное снижение не гарантировано.

Выбираем порог по последствиям ошибок

Пропущенный дефект стоит 20 единиц потерь, лишняя проверка исправного изделия — 1 единицу. Верные решения имеют нулевые потери.

$$L(t) = C_{FN}\,FN(t) + C_{FP}\,FP(t)$$

C_FN и C_FP — потери на одну ошибку; L — суммарные потери на выборке.



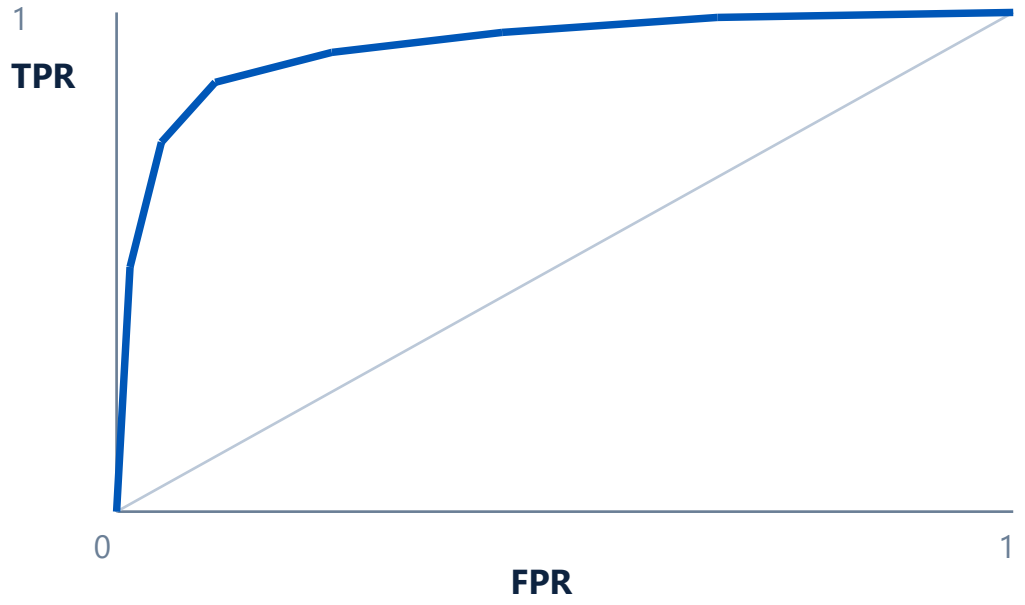
ВЫВОД

Среди трёх проверенных порогов t = 0,50 даёт минимальные потери: 20 × 4 + 40 = 120 единиц. Если каждая проверка имеет собственную стоимость или цена дефекта зависит от изделия, ожидаемые потери нужно записать заново.

ROC: насколько хорошо модель упорядочивает

Каждый порог задаёт точку (FPR; TPR). Таблица показывает расчёт трёх точек; линия справа схематически показывает типичную ROC-кривую по всем порогам.

Порог	TP / FP	TPR / FPR
0,80	10 / 10	50 % / 1,0 %
0,50	16 / 40	80 % / 4,1 %
0,20	18 / 98	90 % / 10,0 %



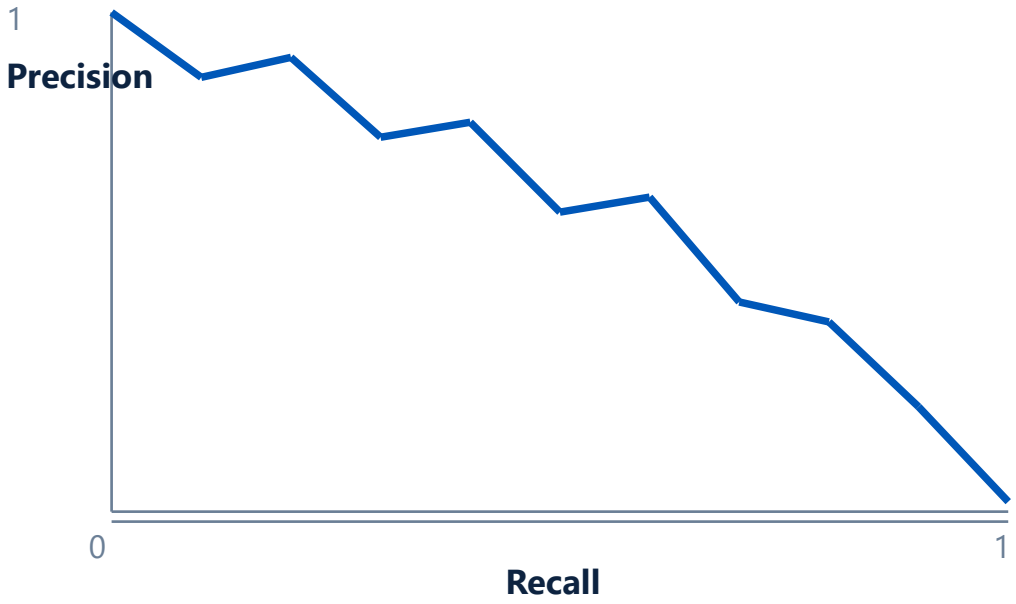
ВЫВОД

ROC-AUC оценивает ранжирование по всем порогам; для рабочего решения отдельно выбирают порог и считают число ошибок.

PR: качество поиска редкого события

Каждый порог задаёт точку (recall; precision). Таблица показывает три точки; линия справа схематически показывает типичную PR-кривую по всем порогам.

Порог	TP / FP	Recall / Precision
0,80	10 / 10	50 % / 50 %
0,50	16 / 40	80 % / 28,6 %
0,20	18 / 98	90 % / 15,5 %



ВЫВОД

При редком дефекте PR-кривая показывает, какая доля назначенных проверок действительно выявляет дефект.

Когда нужны ROC-AUC и PR-кривая

Выбор зависит от того, что хочется сравнить: порядок объектов в целом или полезность потока положительных решений.

ROC-AUC · качество ранжирования

Кейс: кредитные заявки. Нужно сравнить две модели по тому, насколько высоко они ставят будущие просрочки относительно заявок без просрочки.

ROC-AUC показывает качество порядка по всем порогам. Для запуска дополнительно проверяют калибровку и потери при рабочем пороге.

PR-кривая · полезность проверок

Кейс: поиск мошеннических платежей. Мошенничество редко, а аналитики могут проверить лишь часть операций.

PR-кривая показывает долю подтверждённых случаев среди тревог при разной полноте.

ВЫВОД

ROC AUC хорош тем, что стабильно оценивает общее качество разделения классов и не меняется при сдвиге их пропорций, а PR AUC наглядно показывает реальную точность модели на редком целевом классе при сильном дисбалансе данных.

Регрессия: средняя и крупная ошибка

Абсолютные ошибки прогноза доставки: 1, 1, 1 и 9 минут. Большой промах сильнее влияет на RMSE.

$$\text{MAE} = \frac{1}{n}\sum_i |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}, \quad R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

$R^2 = 1$ для точного прогноза; $R^2 = 0$ у прогноза среднего; $R^2 < 0$ означает результат хуже среднего.



ВЫВОД

MAE = 3 мин; RMSE ≈ 4,58 мин. R^2 сравнивает модель с прогнозом среднего.

Какие метрики нужны в разных задачах

Метрику выбирают по вопросу бизнеса. ROC-AUC и PR-кривую используют вместе с показателями при рабочем пороге.

Кейс	Что показывает ROC-AUC	Что показывает PR-кривая
Кредитный риск	Порядок заявок по будущей просрочке	Долю просрочек среди заявок, помеченных как риск
Мошеннические платежи	Способность поднять рискованные платежи выше обычных	Долю подтверждённого мошенничества среди тревог
Поиск дефектов	Ранжирование дефектных и исправных изделий	Долю дефектов среди проверок при нужном recall

ВЫВОД

Для редкого события особенно важны precision и доступная мощность проверки; ROC-AUC не заменяет эти числа.

БЛОК 2

Интерпретируемость ML-моделей

Причины ошибок, объяснения отдельных прогнозов и проверка надёжности.

LIME: какие части изображения важны для ответа

LIME (Local Interpretable Model-agnostic Explanations, локальные интерпретируемые объяснения без привязки к модели) сравнивает прогнозы нейросети для вариантов фотографии автомобиля с закрытыми областями.

Исходное фото



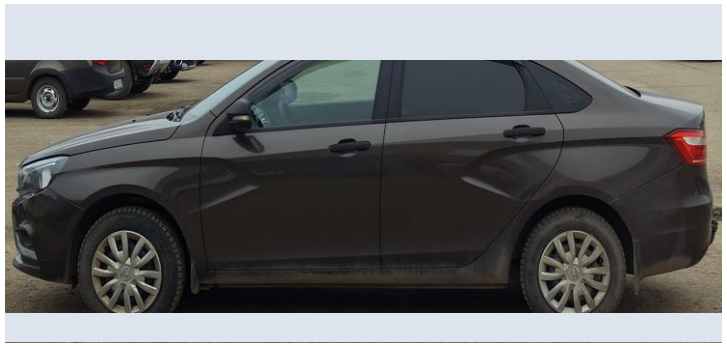
P(авто) = 73 %

Закрыли колёса



P(авто) = 60 %

Закрыли фон



P(авто) = 72 %

ВЫВОД

Закрытие колёс снизило прогноз сильнее, чем закрытие фона. Это наблюдение по двум вариантам, а не готовая оценка вклада LIME.

LIME: как получается локальное объяснение

Пусть f — классификатор изображения, z — вариант с закрытыми областями, g — интерпретируемая модель (линейная регрессия, дерево, например). LIME подбирает g по множеству таких вариантов.

$$g_x = argmin_{g \in G} \sum_k \omega_x(z_k)(f(z_k) - g(z_k))^2 + \lambda\Omega(g)$$

Часть выражения	Что означает
$\omega_x(z_k)$	Вес близости варианта z_k к исходному изображению x
$f(z_k) - g(z_k)$	Различие прогнозов классификатора и объяснения
$\Omega(g)$	Ограничение сложности объяснения

Если простое объяснение хорошо повторяет много близких вариантов, его вес для области «колёса» показывает локальную связь этой области с прогнозом «автомобиль».

ВЫВОД

Вес области в g получают по множеству вариантов; он не равен разности двух отдельных прогнозов.

LIME: когда локальному объяснению можно доверять

Маскирование может создавать изображение, не похожее на обучающие данные. Тогда классификатор отвечает на непривычный вход, а простое объяснение может быть неустойчивым.

Маска

Чем закрыта область:
цветом или размытием?

→

Точность рядом

Повторяет ли g прогнозы f
для близких вариантов?

→

Устойчивость

Остаются ли колёса
важными при новом запуске?

ВЫВОД
Объяснение проверяют на локальную точность и устойчивость; оно не заменяет проверку качества самой модели.

SHAP раскладывает отдельный прогноз на вклады признаков

SHAP (SHapley Additive exPlanations) для того же изображения автомобиля раскладывает выход модели на базовое значение и вклады частей изображения относительно выбранного фона.

$$f(x) = \phi_0 + \sum_{j=1}^{d} \phi_j$$

ϕ_j — вклад j-го признака в конкретный прогноз модели относительно базового значения.

φ_0 — базовый выход; φ_j — вклад признака j; d — число признаков. Все слагаемые имеют одну шкалу.



ВЫВОД

Разложение шансов: база 0,4 + контур 0,5 + колёса 0,3 − фон 0,2 = 1,0.

SHAP: как вычисляют вклад частей фотографии

Нейросеть выдаёт логит класса «автомобиль». Фото делят на три области: контур C, колёса W и фон B. Для каждого набора открытых областей S измеряют выход v(S); скрытые области заменяют фоном.

Открытые области S	∅	C	W	B	CW	CB	WB	CWB
v(S), логит	0,4	0,9	0,7	0,2	1,2	0,7	0,5	1,0

Веса получаются из всех возможных порядков добавления трёх областей: контура C, колёс W и фона B. Таких порядков 3! = 6. В каждом смотрим, насколько изменился выход модели в момент добавления C.

Что уже открыто перед C	Подходящие порядки	Вес
Ничего	CWB, CBW	2/6=1/3
Только W	WCB	1/6
Только B	BCW	1/6
W и B	WBC, BWC	2/6=1/3

SHAP: как вычисляют вклад частей фотографии

Нейросеть выдаёт логит класса «автомобиль». Фото делят на три области: контур C, колёса W и фон B. Для каждого набора открытых областей S измеряют выход v(S); скрытые области заменяют фоном.

Открытые области S	∅	C	W	B	CW	CB	WB	CWB
v(S), логит	0,4	0,9	0,7	0,2	1,2	0,7	0,5	1,0

Вклад области = среднее изменение логита при её добавлении ко всем возможным наборам других областей.

$$\phi_C = \frac{1}{3}[v(C) - v(\emptyset)] + \frac{1}{6}[v(CW) - v(W)] + \frac{1}{6}[v(CB) - v(B)] + \frac{1}{3}[v(CWB) - v(WB)]$$

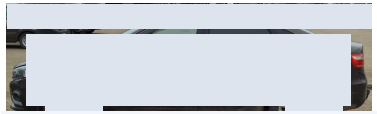
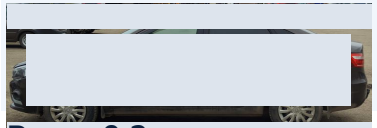
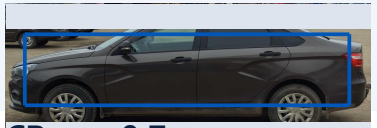
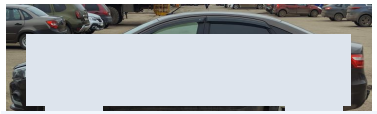
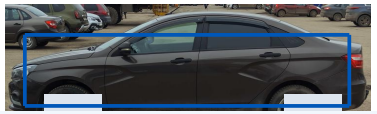
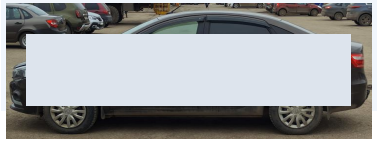
Все четыре разности равны +0,5, поэтому φC = +0,5. Аналогично φW = +0,3 и φB = −0,2.

ВЫВОД

База 0,4 + вклады 0,5 + 0,3 − 0,2 = логит 1,0; вероятность класса «автомобиль» ≈ 73,1 %.

SHAP: вклад контура C получается из четырёх сравнений

В каждой паре открываем контур C. Колёса W и фон B остаются в том же состоянии; выход нейросети сравниваем в логитах.

Без контура C		Добавили C	Разница	Вес	Часть вклада
∅: v = 0,4 	→	C: v = 0,9 	+0,5	1/3	+0,167
W: v = 0,7 	→	CW: v = 1,2 	+0,5	1/6	+0,083
B: v = 0,2 	→	CB: v = 0,7 	+0,5	1/6	+0,083
WB: v = 0,5 	→	CWB: v = 1,0 	+0,5	1/3	+0,167

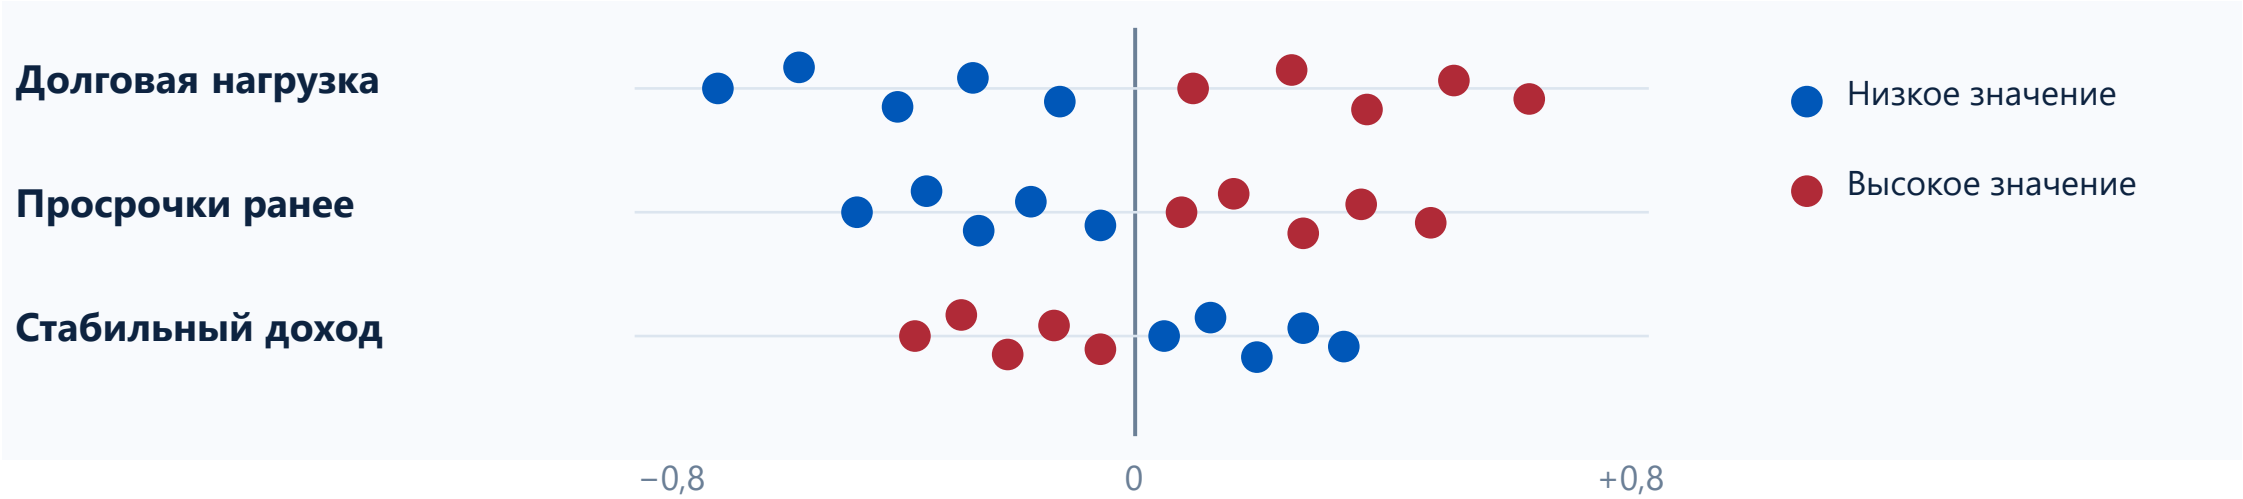
$$\phi_C = \frac{1}{3}\cdot 0.5 + \frac{1}{6}\cdot 0.5 + \frac{1}{6}\cdot 0.5 + \frac{1}{3}\cdot 0.5 = 0.5$$

ВЫВОД

Каждая разница равна +0,5; веса четырёх сравнений суммируются до 1.

SHAP Summary Plot: что видно по кредитным заявкам

Каждая точка — одна заявка. По горизонтали — вклад признака SHAP в логарифм шансов просрочки: вправо он повышает оценку риска, влево снижает.



ВЫВОД

На схеме высокая долговая нагрузка чаще сдвигает оценку риска вправо, а высокий стабильный доход — влево. Это сводка по заявкам, а не объяснение одного решения.

LIME и SHAP в бизнесе: от объяснения к проверке решения

Сценарии показывают, какой вопрос помогает задать объяснение отдельного прогноза. Само объяснение ещё не подтверждает правильность решения.

Сценарий и метод	Что показывает объяснение	Что проверяет команда
Страхование: фото повреждения авто · LIME	При скрытии вмятины оценка класса «повреждение» падает; при скрытии даты на фото почти не меняется.	Сравнить с разметкой эксперта и проверить другие фото, освещение и ракурсы.
Кредит: риск просрочки · SHAP	Высокая долговая нагрузка повышает оценку риска относительно фона; стабильный доход её снижает.	Проверить данные заявки, фон сравнения и качество модели по группам клиентов.
Платежи: подозрительная операция · SHAP	Новый получатель и необычная сумма повышают оценку риска именно этой операции.	Проверить подтверждённые случаи и нагрузку на ручную проверку при выбранном пороге.

ВЫВОД

LIME помогает увидеть, на какие области изображения опирается прогноз; SHAP показывает вклады признаков в выбранной шкале и относительно фона.

Итоги лекций 7–8

Что нужно связать, прежде чем рекомендовать модель к применению.

Вопрос	Инструмент	Что показывает	Что проверить
Какие ошибки?	Матрица, P/R/F1	Сколько найденных событий, пропусков и ложных тревог	Положительный класс и порог
Как ранжирует?	ROC-AUC, PR	Общий порядок и долю полезных тревог при разной полноте	Рабочий диапазон порогов
По чему прогноз?	LIME, SHAP	Области и признаки, связанные с ответом модели	Фон, маску и шкалу
Можно применять?	Потери и нагрузка	Эффект решения с учётом ошибок и ресурсов	Качество на новых данных

ВЫВОД

Следующая тема: как нейронные сети строят признаки и обучаются на изображениях и текстах.